

討論者 土屋 智由 先生

特 別 研 究 報 告 書

題 目 機械学習と微分可能シミュレータの融合による
In-Silico Bone Biopsy の実現

指導教員 安達 泰治 教授

京都大学工学部物理工学科
(機械システム学コース)

氏 名 平塚 謙良

提出年月 令和 8 年 2 月

摘要

高齢社会において、骨粗鬆症に伴う脆弱性骨折は健康寿命延伸の大きな阻害要因である。骨折リスクを評価するために重要とされる骨強度は、骨密度に加えて、海綿骨の構造特性や材料特性を包含する骨質によって規定される。しかし、現行の標準的診断手法である DXA 法は低侵襲に行えるものの、得られる情報としては 2 次元的な骨密度の評価に留まり、骨強度の説明力には限界がある。一方で、詳細な骨質指標や、その背景にある代謝動態等の骨内部状態を得るには、侵襲的な骨生検が必要となる。このように、従来の診断手法においては非侵襲性と情報量のトレードオフが課題であり、これを解決するために機械学習や数理モデルを活用した、*in-silico* 診断手法の開発が期待される。

一般に、機械学習に代表される **Black-box** アプローチは個別データへの適応能力に優れる一方、臨床現場で重視される解釈性に課題がある。一方、数理モデルに基づく **White-box** アプローチは生理学的整合性を担保し得るものの、個別患者への適合が困難である。そこで、両者の長所を統合し、理論的な整合性とデータへの適応能力を両立する **Gray-box** アプローチに基づく手法を提案する。本研究は、非侵襲に取得可能な臨床指標から、個別患者における応力状態、骨微細構造、シグナル分子濃度分布、細胞分布など、詳細な骨内部状態を推定・可視化する計算システム **In-Silico Bone Biopsy (ISBB)** を構築することを目的とする。

本システムは、臨床データから骨密度を推定する機械学習モデルと、骨密度等を境界条件として逆解析を行う微分可能骨代謝シミュレータを疎に結合させた **modular** 型の構成を採用している。まず、機械学習モデルの構築においては、大規模臨床データセットを用いた比較検証の結果、予測値の期待値と分散を同時に出力する **Heteroscedastic** 回帰モデルが最も高い汎化性能を示した。本手法は、単一の点推定に留まらず、生体データの不確実性を定量化することを可能とするモデルである。次に、シミュレータとして、自動微分フレームワーク **JAX** を基盤とした微分可能骨代謝シミュレータを開発した。応力解析から生化学シグナル変換、シグナル分子濃度変化、細胞密度変化、骨界面の移動といった、骨代謝の一連の過程を連続値の場として記述することで、シミュレータ全体を微分可能な形式で統合した。

本シミュレータの順解析能力を検証した結果、単一骨梁スケールから組織スケールに至るまで、荷重条件に応じた力学適応を安定的に再現できることを確認した。加えて、力学的および生化学的因子の変調に伴う多様な骨疾患の進行過程を再現可能であることを示した。本シミュレータの逆解析能力の検証においては、微分可能シミュレータが提供する勾配情報を活用することで、複雑なパラメータ空間における効率的な探索を実現した。双子実験を通じた検証により、勾配ベースの最適化アルゴリズムが、従来の勾配フリー手法と比較して高い推定精度と安定性を有することを実証した。さらに、実際の臨床データを用いたケーススタディにより、本システムが逆解析を活用することで、静的な骨形状と動的な骨代謝状態を含む骨内部状態を推定可能であり、その経時的变化を観察可能であることを示した。

以上のように本研究は、臨床で得られる非侵襲データから、これまで侵襲的な骨生検を通じてしか得られなかった詳細な骨内部の情報を推定し、更にはその経時的变化を観察可能とする **ISBB** を実現するための基盤を確立した。本手法は、骨粗鬆症の病態理解を深化させ、個々の患者の代謝状態に応じた精密な治療方針の策定に寄与するものである。

目次

第1章 緒言.....	1
1.1 骨粗鬆症診断における骨質評価の重要性.....	1
1.2 診断における非侵襲性と情報量のトレードオフ.....	1
1.3 In-Silico Bone Biopsy の実現に向けたアプローチ.....	2
1.4 Gray-box アプローチの課題と微分可能シミュレータ.....	2
1.5 研究目的.....	3
第2章 手法.....	5
2.1 機械学習を用いた骨評価指標の推定.....	5
2.1.1 対象データおよび前処理.....	5
2.1.2 骨密度予測モデルの構築.....	7
2.1.3 骨評価指標の推定.....	8
2.2 微分可能骨代謝シミュレータ.....	9
2.2.1 シミュレータの概要.....	9
2.2.2 有限要素法による応力解析.....	10
2.2.3 力学・生化学変換とシグナル伝達.....	11
2.2.4 移流反応拡散系による細胞動態モデル.....	13
2.2.5 Phase Field 法による骨形状変化.....	14
2.2.6 数値計算と微分可能性の担保.....	15
2.3 In-Silico Bone Biopsy の枠組みと逆解析.....	17
2.4 μ CT を用いた海綿骨モデルの作成.....	19
第3章 結果.....	20
3.1 骨密度予測モデルの精度評価.....	20
3.1.1 各モデルの予測精度の比較.....	20
3.1.2 重要因子の特定と可視化.....	22
3.2 微分可能骨代謝シミュレータの順解析能力の検証.....	22
3.2.1 力学適応能の検証.....	22
3.2.2 骨代謝異常の再現実験.....	25
3.3 微分可能骨代謝シミュレータの逆解析能力の検証.....	27
3.4 In-Silico Bone Biopsy の妥当性評価.....	29
3.4.1 臨床データによるケーススタディ.....	29
3.4.2 骨内部状態の可視化による詳細解析.....	32
第4章 考察.....	35
4.1 In-Silico Bone Biopsy の実現に向けた基盤の確立.....	35
4.2 今後の課題.....	36
4.2.1 生理的課題.....	37
4.2.2 数理的課題.....	37
4.2.3 実装上の課題.....	38

4.3 In-Silico Bone Biopsy の有用性.....	38
4.4 将来の展望	39
第 5 章 結言	41
参考文献	43
謝辞.....	48
付録.....	49
S.1	49
S.2	52
S.3	52
S.4	53

第 1 章 緒言

1.1 骨粗鬆症診断における骨質評価の重要性

生体内の骨組織は、骨芽細胞による骨形成と破骨細胞による骨吸収の連続的なサイクル（骨リモデリング）によって、その恒常性が維持されている[1]。この骨リモデリングは、メカノセンサーである骨細胞を中心とした細胞間シグナル伝達系によって精密に制御されている[2]。その均衡が崩れると、骨減少症（Osteopenia）や骨硬化症（Osteosclerosis）といった多様な骨疾患が惹起される。中でも骨粗鬆症（Osteoporosis）は、骨量の減少と微細構造の劣化により骨強度が低下し、骨折リスクが増大する代表的な骨疾患である。骨強度の低下に伴う脆弱性骨折は、高齢社会において要介護状態を招く主要な要因となっており、健康寿命を延伸する上での阻害要因となっている[3]。

この骨折リスクを規定する骨強度は、骨密度および骨質の二つの要素によって規定されることが知られている[4]。このうち骨質とは、海綿骨の異方性や骨梁連結性といった構造特性、ならびに石灰化度に代表される材料特性を包含する概念であり、複数の指標により定量的に評価される。これらの指標の背景には、海綿骨の 3 次元的微細構造に加え、骨細胞による力学的刺激の感知や、シグナル伝達を介した骨リモデリング動態といった骨内部の状態が関与していることが報告されている[5]。一方、現在、臨床現場で標準的な診断手法となっている二重エネルギー X 線吸収測定（DXA）法による骨密度測定のみでは、骨強度の説明力に限界があることが指摘されている[6]。

したがって、骨強度を適切に評価するためには、骨密度のみならず、上述の微細構造や代謝状態といった骨内部状態を考慮した、多角的な評価が重要である。

1.2 診断における非侵襲性と情報量のトレードオフ

現在、骨内部の状態を評価する手法は複数存在するが、そこには非侵襲性と得られる情報量の間にトレードオフ関係が存在する。

臨床で広く普及している DXA 法は、低被曝かつ短時間で実施可能であり、低侵襲な標準的な手法として用いられている。しかし、DXA 法は 3 次元構造を 2 次元平面へ投影する手法であるため、骨梁の空間的なネットワーク構造や力学的異方性といった 3 次元的な情報が消失するという原理的な限界がある[7]。また、尿や血清から骨吸収・形成速度やそのバランスといった全身の骨代謝回転を評価する骨代謝マーカー（Bone Turnover Markers; BTMs）は、被曝を伴わない非侵襲的な検査手法であるが、測定値の変動要因が多岐にわたる上、局所的な骨組織の構造情報を直接提供するものではない[8]。

一方、研究レベルで用いられる高解像度末梢骨用定量的 CT（High-Resolution peripheral Quantitative CT; HR-pQCT）は 3 次元的な骨微細構造の可視化が可能であるが、被曝が強いことや装置の特殊性から一般に普及するには至っていない。さらに、最も直接的な評価法である骨生検（Bone Biopsy）は、骨組織を実際に採取する侵襲的な処置である。細胞動態や微細構造などの詳細な評価における、骨生検の重要性は依然として認められているもの

の、患者への身体的負担や、低侵襲な代替手法の普及に伴い、一般的な臨床現場で日常的に実施される機会は限定的なものとなっている[9].

このように、診断に資する詳細な 3 次元構造や代謝状態の取得には高い侵襲性が伴うため、臨床現場における定期的な実施は困難である。以上の背景から、臨床で得られる非侵襲なデータを用いながら、骨生検と同等の詳細な骨内部情報を推定する *in-silico* 手法が求められている。そこで本研究は、非侵襲的な臨床指標から個別の患者における詳細な骨内部状態を推定・可視化する計算システム In-Silico Bone Biopsy（以下、ISBB）を提案する。これは、物理的な組織採取を伴う従来の骨生検に対し、計算機上で同等の情報を取得しようとする試みである。

1.3 In-Silico Bone Biopsy の実現に向けたアプローチ

前節で述べた ISBB を実現するには、内部メカニズムの記述方法に応じて、大きく分けて二つのアプローチの応用が考えられる。一般に、機械学習などの内部の仕組みを記述せず、入出力の関係のみに着目する手法は **Black-box** アプローチと呼ばれ、それに対比して、理論や物理法則に基づき内部の挙動を記述する手法は **White-box** アプローチと呼ばれる。

White-box アプローチ、特に骨リモデリングの理論に基づいた数理モデルを用いる手法は、シミュレーションを通じて現象のメカニズムを再現できるため、高い解釈性を有する[10]。しかし、臨床データから複雑な数理モデルのパラメータを特定することは容易ではなく、個別の患者データに対する適応性に課題がある。

一方、**Black-box** アプローチを骨内部状態の推定に応用する場合、機械学習によって血清データ等の臨床指標から直接内部状態を予測する方法が考えられる。この方法は、ニューラルネットワーク等によりデータ間の非自明な相関を学習する事で個別データへの高い適応能力を期待できる反面、学習に必要な教師データとしての骨生検データの収集が困難である点や、計算過程が非明示的な数学モデルに依存するため、臨床現場での意思決定に不可欠な解釈性を欠くという課題がある。

臨床において、医師が正当な判断を下すためには、検査の予測精度の高さだけでなく、解釈性の高さが重要となる。医師が診断の根拠を生物学的機序に基づいて理解することは、治療介入が及ぼす効果の予見性を高め、責任ある治療方針を決定するための基盤となる[11]。

このように、両アプローチは解釈性と個別データへの適応性の面で相補的な関係にある。したがって、理論による生理学的整合性と、データに基づく適応能力を両立する **Gray-box** アプローチの実現が、ISBB を実現し臨床応用するための鍵になると考えられる。

1.4 Gray-box アプローチの課題と微分可能シミュレータ

骨粗鬆症診断の文脈において、数理モデルの解釈性と機械学習の適応能力を融合させる **Gray-box** アプローチは、その構成形式によって **End-to-End (E2E)** 型と **modular** 型に分類できる。

E2E 型は、入力から出力に至る計算過程を単一の計算グラフとして記述し、全パラメー

タを同時に最適化する手法である。物理法則を損失関数に組み込む **Physics-Informed Neural Networks (PINNs)** 等がその代表例である[12]。E2E 型は全体最適化による高い予測精度が期待できる一方で、生理学的制約と統計的学習が密に結合しているため、個々の観測データが生理学的な整合性に与える寄与の評価や、モジュール単位での独立した検証が困難であるという特性を持つ。このような特性から、E2E 型アプローチはモデル内部の挙動や各構成要素の生理学的意味づけの解釈性を十分に担保することが難しい。

これに対し、**modular** 型は、異なる機能を持つ複数の独立なモデルを疎に結合する手法である。具体的には、臨床データから骨評価指標を抽出する機械学習モジュールと、当該指標に基づき骨内部状態を推定する数理モデルモジュールを分離して結合する構成が考えられる。本構成では、臨床データ特有のノイズを機械学習側で統計的に処理し、数理モデルには生理学的定義の明確な指標のみを入力する。これにより、データの不確実性と生理学的な整合性を個別に検証することが可能となり、臨床データから評価指標への統計的マッピングと、数理モデルに基づく内部状態の推定プロセスを段階的に評価できるため、推定結果の生理学的な妥当性の担保が容易となる。

しかし、上記のような構成の **modular** 型アプローチの実装においては、最適化アルゴリズムを用いた数理モデルのパラメータ推定が必要となる。そして、最適パラメータの探索効率が低いと、それに起因する計算コストの増大が実用化における技術的な障壁となる。一方、骨リモデリングを記述する従来のシミュレータは、細胞個別の挙動を追跡するエージェントベースモデルや離散的な確率モデルが主流であり[10], [13]、これらのモデルは不連続性や確率性を内包するため、特殊な緩和手法等を用いない限り微分不能な系として扱わざるを得ない。このような微分不能なシミュレータにおけるパラメータ推定には、ベイズ最適化[14]や **Nelder-Mead 法**[15]等の勾配フリーな手法を用いることがある[16], [17]。しかしながら、これらの手法は高次元のパラメータ空間における探索効率や精度に限界があり、多因子が複雑に絡む骨代謝系の推定において、計算コスト増大の要因となりうる[18]。

この問題を解決するアプローチとして、近年、計算科学の分野では微分可能シミュレータが注目を集めている。これは、シミュレーションの計算過程全体を微分可能な関数として記述し、自動微分を通じて出力に対する入力パラメータの勾配を直接算出可能にする手法である。物理法則に基づく厳密な制約を保持したまま、勾配を利用する最適化アルゴリズムを物理計算に直接適用できるという特性から、流体力学やロボティクス等の様々な分野で導入が進んでいる[19]。

そこで本研究は、骨代謝メカニズムを連続値および場の記述に基づき再構成し、自動微分に対応した微分可能骨代謝シミュレータを開発した。シミュレータが目的関数に対するパラメータの勾配を直接提供することで、**modular** 型の枠組みにおいて大規模なパラメータ空間での高速な収束と、精密なパラメータ推定が可能となる。これにより、理論に基づく生理学的制約を維持しつつ、臨床的に許容される時間内での骨内部状態の推定が実現される。

1.5 研究目的

本研究の目的は、これまで述べた **ISBB** のコンセプトに基づき、実際の計算システムを構




Fig. 1 In-Silico Bone Biopsy のシステム概念図

築し，その妥当性を検証する事である．

本システムにより，具体的には骨梁の 3 次元的な微細構造の経時的変化に加え，破骨細胞・骨芽細胞の局所的な密度分布，それらを制御するシグナル分子の濃度分布，および力学状態といった，従来の臨床検査では直接観測不可能な情報を含む，骨内部状態を推定・可視化する．

この目的を達成するため，1.4 節で詳述した modular 型 Gray-box アプローチに基づき，Fig. 1 に示すような二段階のシステムを構築する．

第一に，血清データやデモグラフィック情報といった臨床データから，シミュレーションの境界条件となる骨体積分率（Bone Volume / Tissue Volume; BV/TV）等の骨評価指標を推定するために機械学習モデルを構築する．具体的にはまず，機械学習によって臨床データから骨密度（Bone Mineral Density; BMD）を予測するモデル（骨密度予測モデル）を構築し，その上で BTMs と，予測した BMD に対して，線形変換等を通じて骨評価指標を導き，数理モデルの境界条件へと統合する．

第二に，自動微分に対応した骨代謝シミュレータ，Differentiable Bone（以下，D-Bone）を開発する．上記の方法により推定された骨評価指標を目標値とし，シミュレータの内部状態から算出される骨評価指標との誤差を最小化するように逆解析を行う．この時，本シミュレータから得られる勾配情報を活用することで，骨代謝メカニズムを記述するための複雑なパラメータ空間において，効率的に患者個別の骨内部状態を推定することが可能になると考えられる．

本研究は，機械学習と微分可能シミュレータの融合による ISBB の実現を通じ，これまで骨生検等の侵襲的な手法でしか得られなかった詳細な骨質情報のみならず，従来手法では直接観測不可能であった骨内部状態を，非侵襲な臨床データから推定する基盤を確立し，骨粗鬆症診断や治療方針策定のさらなる精密化に寄与することを目指す．

第 2 章 手法

本章では、非侵襲的に取得される臨床指標に基づき、患者個別の骨内部状態を推定および可視化する計算システム ISBB の構築手法を詳述する。本システムは、1.4 節で述べた modular 型 Gray-box アプローチに基づき、統計的推定を担う機械学習モジュールと、生理学的な整合性を担保する数理モデルモジュールとを疎に結合させた構成を採用する。まず 2.1 節では、多変量な臨床データからシミュレーションの境界条件となる骨評価指標を、統計的に推定する骨密度予測モデルの構築手法について述べる。次に 2.2 節では、本研究の中核をなす自動微分に対応した骨代謝シミュレータ D-Bone の数理的定式化と、計算過程全体を微分可能な形で統合する実装技術について詳述する。2.3 節では、これら二つのモジュールを融合し、シミュレータから得られる勾配情報を利用して、患者個別の骨内部状態を効率的に推定する逆解析の枠組みを提示する。最後に 2.4 節では、シミュレータの初期骨形状となる海綿骨モデルの作成手法について述べる。

2.1 機械学習を用いた骨評価指標の推定

本節では、D-Bone の逆解析における境界条件として用いる骨評価指標を、臨床データに基づき導出する手法について述べる。本研究では、まず、機械学習アルゴリズムを適用し、臨床データから BMD の Z スコアを推定する。次いで、得られた Z スコアに対し、既存文献に基づく統計的仮定の下で線形変換を施すことで BV/TV を算出する。さらに、臨床的に取得可能な BTMs である尿中 N-テロペプチド (urinary cross-linked N-Telopeptide; uNTx) や骨型アルカリホスファターゼ (Bone specific Alkaline Phosphatase; BAP) の Z スコアについても線形変換を適用し、患者固有の骨形成速度および骨吸収速度を算出する。これらの値を、逆解析における境界条件として用いる。

2.1.1 対象データおよび前処理

骨密度予測モデルの構築には、米国疾病予防管理センター (Centers for Disease Control and Prevention; CDC) が実施した大規模健康調査データセットである National Health and Nutrition Examination Survey (NHANES) を採用した。NHANES は、疫学研究において広く利用されており、先行研究においても、本データセットを用いた深層学習による疾患リスク予測の有効性が報告されている [20]。本研究では、uNTx や BAP などの BTMs の指標を含む、1999-2000 年および 2001-2002 年の 2 サイクル分のデータを統合して使用した。独立変数として血清バイオマーカー、身体計測値、およびデモグラフィック情報を採用し、従属変数には DXA 法により測定された右大腿骨の BMD データを設定した。右大腿骨 BMD を選択した理由は、2.4 節にて後述するように本研究では D-Bone における初期 3 次元骨形状としてブタ大腿骨を用いており、その対応関係を考慮したためである。本研究では、BV/TV のような無次元指標への写像を介することで、種差や形状差に起因する影響が統計的に吸収されると仮定した。各カテゴリに分散して存在する生データについては、被験者識別番号 (Sequence Number; SEQN) に基づき統合処理を行った。この過程において、欠損

率が高い項目や予測性能への寄与が小さいと判断された指標を除外した．最終的に得られたデータ数は 8722 件であり，そのうち 80%を学習用データ，残りを評価用データとして用いた．予測モデルの学習に用いた説明変数，ならびに予測対象である BMD の内訳を Table 1 に示す．

Table 1 学習に用いるパラメーター一覧

パラメータ名	Mean $\pm$ SD	対数変換	定義 (単位)
BMXWT	60.15 $\pm$ 29.85	○	Weight (kg)
BMXHT	156.3 $\pm$ 22.92	-	Standing Height (cm)
LBXCRP	0.358 $\pm$ 0.795	-	C-reactive protein (mg/dL)
LBXBAP	33.33 $\pm$ 37.19	○	Bone alkaline phosphatase (ug/L)
URXNT	1083. $\pm$ 2084.	○	N-telopeptides (NTx) (nmol BCE)
RIAGENDR	1.514 $\pm$ 0.5	-	Gender of the sample person
RIDAGEMN	346. $\pm$ 286.	-	Best age in months
DXXRLBMD	1.137 $\pm$ 0.177	-	Right Leg Mineral Density (g/cm ²)
LBXSAL	4.374 $\pm$ 0.368	-	Albumin (g/dL)
LBXSATSI	23.68 $\pm$ 27.28	○	ALT (U/L)
LBXSASSI	24.25 $\pm$ 15.49	○	AST (U/L)
LBXSAPSI	102.3 $\pm$ 73.6	○	Alkaline phosphatase (U/L)
LBXSBU	13.18 $\pm$ 5.565	○	Blood urea nitrogen (mg/dL)
LBXSCA	9.479 $\pm$ 0.415	-	Calcium, total (mg/dL)
LBXSCH	187.5 $\pm$ 43.34	-	Cholesterol, total (mg/dL)
LBXSC3SI	23.57 $\pm$ 2.308	-	Bicarbonate (mM)
LBXSGTSI	26.97 $\pm$ 39.97	○	GGT (U/L)
LBXSGL	93.85 $\pm$ 31.4	○	Glucose (mg/dL)
LBXSIR	87.71 $\pm$ 37.49	-	Iron (ug/dL)
LBXSLDSI	144.1 $\pm$ 34.54	○	LDH (U/L)
LBXSPH	3.796 $\pm$ 0.66	-	Phosphorus (mg/dL)
LBXSTB	0.657 $\pm$ 0.307	○	Bilirubin, total (mg/dL)
LBXSTP	7.481 $\pm$ 0.488	-	Protein, total (g/dL)
LBXSTR	129.6 $\pm$ 120.5	○	Triglycerides (mg/dL)
LBXSUA	5.231 $\pm$ 1.471	-	Uric acid (mg/dL)
LBXSCR	0.777 $\pm$ 0.456	○	Creatinine (mg/dL)
LBXSNASI	139. $\pm$ 2.558	-	Sodium (mM)
LBXSKSI	4.078 $\pm$ 0.339	-	Potassium (mM)
LBXSCLSI	102.5 $\pm$ 2.824	-	Chloride (mM)
LBXSOSI	277.4 $\pm$ 5.553	-	Osmolality (mOsm/kg)
LBXSGB	3.107 $\pm$ 0.428	-	Globulin (g/dL)

モデルの学習収束性および予測の頑健性を担保するため、以下の前処理を適用した。まず、各変数の分布を確認し、ひずみが大きい変数に対しては、正規性の改善を目的として対数変換を適用した。対象とした変数は Table 1 の対数変換欄に示す通りであり、次式により変換を行った。

$$x' = \ln(x + 1) \quad (2.1)$$

ここで、加算項 1 は、測定値が 0 付近に存在する場合における対数計算の不安定性を回避するための定数である。

次に、各変数の第 1 四分位数 Q_1 および第 3 四分位数 Q_3 から算出される四分位範囲 $IQR = Q_3 - Q_1$ を用い、 $[Q_1 - k \times IQR, Q_3 + k \times IQR]$ の範囲外に位置するデータを統計的外れ値として除外した。本研究では付録 S.2 における予備検討に基づき、 $k = 6.5$ を採用した。この設定により、生体データの多様性を維持しつつ、極端な測定誤差を排除した。最後に、全特徴量に対し平均 0、分散 1 となるよう Z スコア標準化を適用した。

2.1.2 骨密度予測モデルの構築

臨床データに代表される複雑かつ非線形な関係を有するテーブルデータから高精度に BMD を推定することを目的として、基礎的な線形モデルから近年提案されている深層学習モデルまでを比較検討した。本研究で検討した各モデルの概要を Table 2 に示す。

Table 2 検討した機械学習アルゴリズム

モデル名	概要
線形回帰	基準となる基礎的な線形近似モデル
MLP	複数の全結合層による非線形回帰モデル
1D CNN	入力パラメータ間の局所的な相関を抽出
GBDT[21]	決定木アンサンブルにより欠損や外れ値に強く、テーブルデータで高い性能を発揮
Transformer[22]	自己注意機構により、臨床指標間の大域的な依存関係をモデル化
条件付き拡散モデル[23]	生体データの分布を学習し、確率的に目的変数を生成
Heteroscedastic 回帰[24]	予測値の期待値と分散を同時に出力し、予測の不確実性を定量化

Transformer を用いたモデルでは、1 次元の特徴量ベクトルを疑似的な系列データとして解釈し、Transformer Encoder に入力した。具体的には、各入力特徴量を線形層によって埋め込み空間へ写像した後、位置エンコーディングを加算することで特徴量間の順序情報を付与した。その後、自己注意機構を用いて特徴間の依存関係を学習し、最終層直前において系列方向のグローバル平均プーリングを適用することで、固定長の特徴ベクトルへ集約した。

さらに、生体データに内在する不確実性を明示的に考慮するため、確率分布を直接扱う推定手法を導入し、比較対象に含めた。条件付き拡散モデルでは、入力された生体指標を条件

変数として与え、逆拡散過程を通じてガウスノイズからターゲット指標を段階的に生成する構成を採用した。拡散モデルには 1D CNN を基盤とした U-Net アーキテクチャを用い、補助的に Query, Key, Value を 1D CNN により生成する注意機構を組み込んだ。

Heteroscedastic 回帰モデルでは、通常の MLP を拡張し、出力として期待値と分散を同時に推定する構成とした。この構成により、推定された分散を予測の信頼度として解釈することが可能となり、各推定結果の妥当性を定量的に評価できる。

これらのモデルの予測性能は第 3 章において定量的に比較し、以降の実験では最も高い汎化性能を示したモデルを採用した。

2.1.3 骨評価指標の推定

学習済みモデルより得られた BMD の Z スコアの予測値 $\hat{Z}_{BMD}$ 、および臨床データに含まれる BTMs に基づき、シミュレーションの逆解析における境界条件として用いる骨評価指標を算出する。BMD が長期間にわたる骨代謝の結果として蓄積された骨基質量を表す静的指標であるのに対し、BTMs はサンプリング時点における骨の代謝回転を反映する動的指標といえる。両者を目標値として統合的に用いることで、後段の D-Bone の逆解析において患者固有の骨リモデリング動態を推定することを目的とする。

まず、予測された BMD の Z スコア $\hat{Z}_{BMD}$ から、骨強度に関連する指標である BV/TV を導出する。本手法では、NHANES データセットにおいて BMD がおおむね正規分布に従うことに着目した。これに対応して、先行研究によれば、ヒト大腿骨頭の BV/TV も正規分布に近い分布特性を示し、その平均 $\mu_{BV/TV}$ は 0.3、標準偏差 $\sigma_{BV/TV}$ は 0.05 であることが報告されている[25]。ここで、BMD と BV/TV の間に強い正の相関関係が存在するという知見に基づき[26]、両者の分位点が一对一に対応すると仮定すると、BMD の Z スコアを BV/TV の分布へ写像する変換は、平均および分散の差によって規定される線形変換として定式化できる。以上より、本研究では次式に示すモデルを用いて BV/TV_{pred} を算出する。

$$BV/TV_{pred} = \hat{Z}_{BMD} \times \sigma_{BV/TV} + \mu_{BV/TV} \quad (2.2)$$

次に、骨リモデリングにおける形成および吸収速度を定量化するため、BTMs を利用する。骨形成指標の算出には、骨芽細胞による骨基質形成過程において血中に放出される BAP を採用する。BAP は骨芽細胞の細胞膜に局在する酵素であり、血中濃度を通じて骨形成活性を特異的に反映する指標である。一方、骨吸収指標の算出には、破骨細胞による骨基質分解の産物である uNTx を用いる。uNTx は I 型コラーゲンの架橋構造が分解される際に生成される断片であり、骨吸収の活性を感度高く反映する指標とされている[8], [27]。

これら二つの BTMs は、個体ごとの代謝バイアスを D-Bone の境界条件として反映させる上で重要な生化学的パラメータである。本研究では、各被験者の BAP および uNTx の Z スコアに対し、線形変換を適用することで、目標骨形成量 $\hat{V}_{form}$ および目標骨吸収量 $\hat{V}_{res}$ を算出する。

$$\hat{V}_{form} = (Z_{BAP} \times \alpha_{form}) + \beta \quad (2.3)$$

$$\hat{V}_{res} = (Z_{uNTx} \times \alpha_{res}) + \beta \quad (2.4)$$




Fig. 2 D-Bone のシステム概要

ここで、 α はスケーリング係数、 β は基底値である．これらの値は、D-Bone における骨量変化が発散せず、かつ生理学的に妥当な時間スケールで安定的に推移することを指標とした予備的感度解析に基づき決定した（付録 S.3）．本定式化により、臨床検査値に基づく代謝活性の相対的偏差を、数理モデルにおける境界条件として組み込むことが可能となる．

2.2 微分可能骨代謝シミュレータ

本節では、ISBB の中核を成す微分可能骨代謝シミュレータ D-Bone について述べる．まず、Fig. 2 に示す各サブモデルの定式化を順に示し、最後にそれらを統合することで、次節で述べる逆解析に適用可能な計算モデルがどのように構成されるかを示す．なお、本研究において微分可能とは、骨代謝シミュレーションの計算過程全体が連続値演算として記述され、自動微分フレームワークを適用することにより、出力に対するモデルパラメータの勾配が数値的に安定して計算可能であることを意味する．

2.2.1 シミュレータの概要

本研究で提案する D-Bone は、Kameo らによって提案された骨代謝数理モデル V-Bone[10]を基盤としている．V-Bone では、骨細胞が感知する力学情報が生化学情報として破骨・骨芽細胞へと伝達され、リモデリングにより骨構造が力学環境に応じて変化する適応現象を、分子や細胞の相互作用をボトムアップに記述する事でモデル化している．本研究では、このようなミクロな素過程から、マクロな骨評価指標を算出する過程を逆解析することで、患者個別の骨内部状態の推定を目的とする．そのためには V-Bone の特徴である、骨代謝の基本原則に基づく骨の力学適応の表現性能を保存しながら、逆解析を可能とするシステムを構築する必要がある．これを実現するため、V-Bone が骨組織や細胞の挙動を離散のかつ確率的なイベントとして記述するのに対し、D-Bone では細胞数および骨形状を連続値の場として再定義し、確率遷移や離散イベントを含まない連続時間モデルへと再構成した．

この定式化により、自動微分による勾配計算が可能となり、後述する逆解析アルゴリズムが適用可能となる。

D-Bone における一連の計算プロセスは、Fig. 2 に示すように、骨内部の応力状態の算出、応力から生化学的な力学刺激比への変換、生化学シグナル分子濃度分布の決定、細胞密度の遷移、および骨形状の更新からなるフィードバックループとして構成される。具体的にはまず、現時刻の骨形状に基づき有限要素法を用いて応力場を計算し、得られた力学刺激を、骨細胞による **mechanotransduction** 機構を介して破骨・骨芽細胞活動を制御する骨代謝シグナル分子へと変換する。次いで、反応拡散系により算出されたシグナル分子濃度分布に従い、移流反応拡散方程式を解くことで破骨・骨芽細胞の密度分布を更新する。最後に、これら細胞活動の正味の結果である骨形成・吸収量を駆動力とし、**Phase Field** 法によって骨界面を移動させることで形状変化を記述する。

以上のように、各サブモデル内の状態変数を連続値の場として記述することで、シミュレーション全体を微分可能な計算過程として構築した。

2.2.2 有限要素法による応力解析

本節では Fig. 2 の応力解析モデルについて述べる。応力解析モデルでは、骨組織内部に生じる力学的刺激を定量的に評価するため、連続体力学に基づく有限要素法 (**Finite Element Method; FEM**) による応力解析を行う。解析領域 Ω は、シミュレーションによって骨形状が変化する設計領域と、荷重伝達および拘束を担う非設計領域から構成される。本研究では、ボクセル形状の規則直交格子を用いたボクセル有限要素法を採用し、各要素を 8 節点 1 次六面体要素として離散化する [28]。

複雑な幾何形状と多相の材料分布を統一的に扱うため、構造最適化における材料分布の考え方を導入し、要素内の材料分布を連続的な存在確率として表現する多材料要素剛性補間モデルを構築する [29]。本手法では、要素剛性マトリクス K_e を各相（骨髄、骨組織、支持部材）の基底剛性マトリクスの線形結合として定義する。各要素 e における剛性マトリクスは、相 $m \in \{\text{marrow, bone, fixture}\}$ に対する存在重み $w_{e,m}$ を用いて次のように構成される。

$$K_e = \sum_m w_{e,m} K_e^{(m)} \quad (2.5)$$

ここで、 $K_e^{(m)}$ は各材料特性に基づき算出された要素剛性マトリクスである。設計領域内における骨組織の存在確率は、**Phase Field** 変数 $\phi \in [0, 1]$ によって定義される。本研究では、 ϕ を材料分布、骨組織の形状マスク、および界面表現を兼ねる統一的な状態変数として扱う。さらに、物理的な相分離を促進しつつ数値的な安定性を確保するため、補間関数 $\hat{\phi}(\phi)$ として **Quintic Smoothstep** 関数を導入する。

$$\hat{\phi}(\phi) = 6\phi^5 - 15\phi^4 + 10\phi^3 \quad (2.6)$$

設計領域における各重みは $w_{e,\text{bone}} = \hat{\phi}(\phi)$ 、 $w_{e,\text{marrow}} = 1 - \hat{\phi}(\phi)$ と定義され、非設計領域においては常に $w_{e,\text{fixture}} = 1$ に固定される。これにより、ボクセル格子上の密度分布と

して骨形状と、力学的な境界条件を与えるための支持部材を同時に表現することが可能となる。構築された全体剛性方程式 $Ku = f$ を、与えられた境界条件の下で解くことにより、節点変位ベクトル u を得る。

得られた変位ベクトルに基づき、要素内で一定と仮定したひずみ $\epsilon = Bu$ を算出する。ここで、材料補間モデルから直接導出される応力は、要素内を均質化した多孔質体としての見かけの応力であり、個々の骨細胞が受容する局所的な力学刺激を必ずしも反映していない。そこで本研究では、算出されたひずみ ϵ に対し、骨組織本来の材料特性（ヤング率 E_{bone} 、ポアソン比 ν_{bone} ）に基づく構成則を改めて適用することで、組織レベルの局所的な応力状態を抽出する。最終的に、この局所応力に基づき、以下のフォン・ミーゼス応力 σ_{vM} を算出する。

$$\sigma_{vM} = \sqrt{\frac{(\sigma_{11} - \sigma_{22})^2 + (\sigma_{22} - \sigma_{33})^2 + (\sigma_{33} - \sigma_{11})^2 + 6(\sigma_{12}^2 + \sigma_{23}^2 + \sigma_{31}^2)}{2}} \quad (2.7)$$

なお、骨髄等の低剛性領域における数値的不安定性に起因するひずみの影響を排除するため、 ϕ が閾値を下回る領域においては、骨組織が実質的に存在しないとみなし、等価応力値を 0 とする。この処理により、物理的に妥当な骨組織内部の応力分布のみを抽出することが可能となる。この閾値処理は、Heaviside 関数の平滑近似を用いて連続的に実装している。算出された σ_{vM} は、次項で述べる骨細胞の **mechanotransduction** 機構の直接的な入力値となる。

2.2.3 力学・生化学変換とシグナル伝達

本項では Fig. 2 の力学・生化学変化モデル及びシグナル伝達モデルについて述べる。力学・生化学変換モデルにおける、力学的負荷を生物学的シグナルへと変換する過程は、**mechanotransduction** 機構として定式化される。本研究では、骨細胞が局所的な応力を感じ、そのシグナルを近傍の骨表面へ伝達することで骨リモデリングの駆動力を生成するという数理的枠組み[30]を基盤としている。本モデルでは、この枠組みを継承しつつ、数値解析上の安定性向上および自動微分への適合を目的とした平滑化を行い、以下の定式化を導入した。

第一に、骨細胞による局所的な刺激受容 S_{ocy} の定式化において、フォン・ミーゼス応力 σ_{vM} に対して応答の最小閾値 $\sigma_{\min}$ および最大閾値 $\sigma_{\max}$ を考慮に入れた有効応力 σ_{eff} を、**softplus** 関数および **sigmoid** 関数を用いて次式のように定義する。

$$\sigma_{\text{eff}} = \left[\sigma_{vM} - \frac{1}{k_{\text{stress}}} \text{softplus}(k_{\text{stress}}(\sigma_{vM} - \sigma_{\max})) \right] \cdot \text{sigmoid}(k_{\text{stress}}(\sigma_{vM} - \sigma_{\min})) \quad (2.8)$$

ここで、 k_{stress} は遷移の急峻さを制御するパラメータである。本定式化により、 $\sigma_{vM} < \sigma_{\min}$ では有効応力は 0 へと漸近し、 $\sigma_{vM} > \sigma_{\max}$ の領域では実質的に飽和する滑らかな応答が記述される。これは力学刺激に対する閾値応答と、感度の飽和という生物学的特性を表現する

と同時に、区分的な関数を用いる際に生じる勾配の不連続性を回避し、自動微分における数値的安定性を確保するための処置である。

この有効応力 σ_{eff} に骨細胞密度 ρ_{ocy} および骨組織の存在範囲を規定する Phase Field 変数 ϕ を乗じることで、局所刺激 $S_{\text{ocy}} = \sigma_{\text{eff}} \cdot \rho_{\text{ocy}} \cdot \phi$ を算出する。この積構造は、力学刺激、骨細胞、および骨組織のいずれかが欠如する領域において刺激が発生しないという、物理的・生物学的整合性を担保するためのものである。

第二に、骨細胞ネットワークを介した刺激の空間的な伝播を表現するため、代表伝達距離 lL を有する近傍領域 Ω における空間積分を導入する。本モデルでは、積分範囲内の骨体積分率による正規化を施した以下の形式を採用した。

$$S_d = \frac{\int_{\Omega} w(r) S_{\text{ocy}} d\Omega}{\int_{\Omega} w(r) \phi d\Omega} \quad (2.9)$$

重み関数 $w(r)$ は距離 r に応じて $w(r) = \max(1 - r/lL, 0)$ と線形に減衰するものとする。この定式化により、骨梁の厚みや局所的な欠損に起因する刺激の過小評価が緩和され、組織量に対して適切な伝達刺激量 S_d を得ることが可能となる。

最終的な力学刺激比 S_r は、この局所刺激と近傍平均刺激の比 $S_r = S_{\text{ocy}}/S_d$ として定義される。比を用いることで、刺激強度の絶対値に依存せず、周囲環境に対する相対的な過負荷・低負荷状態を評価できる。この刺激比 S_r は無次元量であり、 $S_r = 1$ を、力学的恒常状態を表す基準値と定義し、 $S_r > 1$ を過負荷、 $S_r < 1$ を低負荷状態として解釈する。また、骨領域外において S_r を低負荷状態に固定することで、後述する力学刺激に起因する骨芽細胞の分化を抑制し、その活動を骨界面に限定させている。これは、骨表面から離脱した位置での不自然な骨形成を防止し、生理学的な妥当性を担保するための処置である。

次にシグナル伝達モデルでは、骨代謝に関与する各シグナル分子の濃度場 $C_i(x, t)$ の時間発展を、以下の一般化された反応拡散方程式によって記述する。

$$\frac{\partial C_i}{\partial t} = P_i - k_{\text{deg}}^i C_i + D_i \nabla^2 C_i + \sum_j R_{i,j} \quad (2.10)$$

ここで P_i は外生的または刺激依存的な一次産生項、 k_{deg}^i は分解係数、 D_i は拡散係数、 $\sum R_{i,j}$ は他分子との相互作用に基づく反応項を表す。本研究では、骨形状の変化速度に比して生化学的反応が十分に速いことから、各ステップにおいて生化学シグナルは準定常状態にあると仮定し、定常解 $\partial C_i / \partial t = 0$ を算出する。刺激比 S_r の変化に応じて各サイトカインの産生量 P_i が制御され、これを通じて細胞間相互作用が展開される。

骨形成抑制因子である Sclerostin は、骨細胞が感知した力学刺激比 S_r の増大に応じてその産生が抑制される[31]。この過程を、Sclerostin の産生量 P_{SCL} が、 S_r に対して抑制型の Hill 関数を用いて制御されるものとしてモデル化する。これにより力学刺激が不足している領域ほど Sclerostin が高濃度に分布することになる。次に、この Sclerostin 濃度分布 C_{SCL} は、破骨細胞の分化誘導因子である RANKL の産生を制御するシグナルとして機能する。RANKL 産生は、局所的な Sclerostin 濃度に依存する促進型の Hill 関数によって記述され、

Sclerostin が高い領域ほど RANKL の放出が亢進される．一方で，骨芽細胞からは RANKL のデコイレセプターとして機能する OPG が一定の割合で産生される．放出された RANKL と OPG は互いに結合し，中和反応を通じてその活性が局所的に減じる．

また，カップリング因子としての役割を担う Sema3A は骨細胞から産生され，骨表面の受容体 Nrp1 および Plexin-A と結合して Sema3A-Nrp1-Plexin-A 複合体を形成する．この複合体の局所濃度は化学平衡に基づいて算出され，破骨細胞の抑制と骨芽細胞の分化促進を同時に誘発する[32]．また，骨リモデリングにおいて，破骨細胞による骨吸収から骨芽細胞による骨形成への遷移期間はリバーサルフェーズと定義される．本モデルでは，このプロセスの進行度を数理的に記述するため，リバーサルフェーズ変数 t_{rev} を導入した． t_{rev} は，破骨細胞の吸収活性に比例して減衰し，吸収終了後は一次動力学に基づき，時定数 T_{rev} に従って回復する挙動を示す．そして， t_{rev} に対して線形に減少する形で産生される骨基質由来成長因子 (Matrix-Derived Growth Factor; MDGF) を定義することで，骨吸収と骨形成のカップリング機序を補完している．なお，MDGF が骨吸収に伴い放出・活性化される生物学的機序については，Fuller らによって示されている[33]．

以上の相互作用を介して， S_r が恒常状態 ($1.0 \pm \delta$) から逸脱した際に生化学的な不均衡が生じ，過負荷領域では骨形成が，低負荷領域では骨吸収が優位となる自己組織的な構造最適化プロセスが記述される．

2.2.4 移流反応拡散系による細胞動態モデル

次に Fig. 2 の細胞動態モデルについて述べる．骨代謝動態を記述するため，本研究では破骨細胞 (Osteoclast) および骨芽細胞 (Osteoblast) の時空間的な密度分布を，移流反応拡散系に基づいた連立偏微分方程式によりモデル化する．各細胞種 $j \in \{Ocl, Obl\}$ に対する密度 ρ_j の時空間発展は，以下の支配方程式によって記述される．

$$\frac{\partial \rho_j}{\partial t} + \nabla \cdot (v_j \rho_j) = S_{\text{source},j} - S_{\text{sink},j} + D_{\text{reg},j} \nabla^2 \rho_j \quad (2.11)$$

ここで，拡散項 $D_{\text{reg},j} \nabla^2 \rho_j$ は，細胞が界面近傍に局在することによる数値的不安定性を抑制するために導入された正則化項であり，細胞の物理的な拡散運動を表現するものではない．

移流項 $\nabla \cdot (v_j \rho_j)$ における速度場 v_j は，界面の移動に伴う受動的な追従成分，すなわち Stefan 速度 v_{stefan} と，細胞独自の能動的な移動成分の合成として定義される．ここで Stefan 速度とは，界面の進化によって生じる物質点の見かけの移動速度を指す．骨表面の法線ベクトルを $n = \nabla \phi / |\nabla \phi|$ とすると，界面移動速度は $v_{\text{stefan}} = -(\partial \phi / \partial t) \nabla \phi / |\nabla \phi|^2$ と記述される．これは Phase Field の時間変化を界面の法線方向速度として解釈したものであり，後述する Allen-Cahn 方程式によって記述される界面進化と整合的な速度表現である．数値計算上， $\partial \phi / \partial t$ は独立した変数として解くのではなく，破骨細胞による吸収速度および骨芽細胞による形成速度の差分から法線方向の移動速度として再構成される．移流項における速度場について，特に破骨細胞の速度場 v_{Ocl} は，以下のように定式化される．

$$v_{\text{Ocl}} = v_{\text{stefan}} + v_{\text{tan}} \frac{v_{\text{crawl}}}{|v_{\text{crawl}}|} + v_{\text{drift}} \quad (2.12)$$

ここで v_{crawl} は界面接線方向の移動ベクトルであり、骨年齢 t_{mat} の正の勾配方向への移動成分と、OPG 濃度 C_{OPG} の負の勾配方向への走化性成分を統合し、界面法線成分を除去することで得られる。スカラー係数 v_{tan} は接線方向移動の大きさを規定し、その方向は正規化された $v_{\text{crawl}}/|v_{\text{crawl}}|$ によって与えられる。なお、勾配が消失する領域では速度場が定義されないため、数値実装においては計算の安定性を考慮し、界面近傍に限定して計算を有効化している。一方、骨芽細胞の速度場 v_{obl} は、Stefan 速度と、界面への拘束を目的とした補助的な法線方向の復元成分 v_{drift} の合成により構成される。

反応項 $S_{\text{source},j}$ および $S_{\text{sink},j}$ は、それぞれ細胞の分化およびアポトーシスを規定するソース項およびシンク項である。これらは以下の一般形式をとる。

$$S_{\text{source},j} = k_{\text{diff},j} \cdot \psi_{\text{diff},j} \cdot \Psi \cdot \left(1 - \sum_k \frac{\rho_k}{K_{\text{max},k}}\right) \cdot M_{\text{acc}}(\phi) \quad (2.13)$$

$$S_{\text{sink},j} = k_{\text{apop},j} \cdot \psi_{\text{apop},j} \cdot \rho_j \quad (2.14)$$

ここで、ソース項の Ψ は分化が生じる領域を骨表面に制限する界面マスクであり、 $(1 - \sum \rho_k / K_{\text{max},k})$ は局所的な細胞密度の増大に伴う分化抑制を表現している。また、アクセス・マスク M_{acc} は Phase Field 変数 ϕ に基づく閾値関数であり、前駆細胞が物理的に侵入不可能な高密度骨領域における分化を制限する役割を担う。反応活性 ψ は、シグナル分子および力学刺激比 S_r の影響を、Hill 関数 $H(C)$ を用いた論理演算により統合したものであり、以下の各数式により定義される。

$$\psi_{\text{diff,Ocl}} = 1 - \{1 - H(C_{\text{RANKL}})(1 - H(C_{\text{SNP}}))\}(1 - H(t_{\text{mat}})) \quad (2.15)$$

$$\psi_{\text{apop,Ocl}} = 1 - (1 - H(S_r))(1 - H(C_{\text{MDGF}})) \quad (2.16)$$

$$\psi_{\text{diff,Obl}} = 1 - \{1 - H(C_{\text{SNP}})(1 - H(C_{\text{SCL}}))\}(1 - H(C_{\text{MDGF}})) \quad (2.17)$$

$$\psi_{\text{apop,Obl}} = \{1 - H(S_r)(1 - H(C_{\text{SCL}}))\}(1 - H(C_{\text{MDGF}})) \quad (2.18)$$

ここで、論理否定を $1 - H$ 、論理積を積の形式で近似的に表現している。骨年齢 t_{mat} は時間の経過とともに上昇し、骨芽細胞による形成活動に伴い指数関数的にリセットされる独立した状態変数である。また、 C_{SNP} は Sema3A-Nrp1-Plexin-A 複合体の濃度である。

以上のように、細胞の移動や、アポトーシス・分化といった諸現象はすべて場の方程式として記述されており、離散的イベントを含まない。そのため、本モデルは自動微分に適した構造を有し、随伴変数法などを用いたパラメータ最適化への適用が容易である。数値計算においては、移流項に保存形の一次風上差分法を適用することで、密度の非負性および質量保存性を保証している。

2.2.5 Phase Field 法による骨形状変化

最後に Fig. 2 の骨形状変化モデルについて述べる。骨形状の経時的変化を追跡するため、本研究では数値的安定性と微分可能性の確保を目的として、従来の Level Set 法に代わり

Phase Field 法を採用する。Phase Field 法では、Phase Field 変数と呼ばれる連続関数 $\phi(r, t)$ を用いて領域内の相の状態を表現する。本モデルにおいて、骨組織が存在する骨相は $\phi \approx 1$ 、骨髄に相当する骨髄相は $\phi \approx 0$ として定義される。これら二相の境界である骨界面は、 $0 < \phi < 1$ の値をとる有限の幅を持った遷移層として表現される[34]。界面幅を決定するパラメータ ϵ は、数値解像度の観点から、先行研究[34]に倣い空間格子幅 Δx と同等の次数に設定した。

骨形成および骨吸収に伴う界面移動は、界面運動の記述における数学的基礎である Allen-Cahn 方程式[35]を拡張し、生物学的駆動力を組み込んだ以下の展開式により記述される。

$$\frac{\partial \phi}{\partial t} = M \left(\nabla^2 \phi - \frac{1}{\epsilon^2} g'(\phi) \right) + F_{\text{bio}} |\nabla \phi| \quad (2.19)$$

本式において、 M は界面の移動速度を規定するモビリティ係数である。右辺第 1 項の拡散項 ($\nabla^2 \phi$) は界面の曲率効果を表現し、表面エネルギーを最小化するように界面を平滑化する作用を持つ。第 2 項は二重井戸型ポテンシャルの導関数 $g'(\phi)$ に基づく相分離項であり、本研究では $g'(\phi) = 2\phi(1 - \phi)(1 - 2\phi)$ と定義する。この項は、 ϕ を安定状態である 0 または 1 へと分離させ、界面プロファイルを維持する役割を担う。さらに、第 3 項の反応項 $F_{\text{bio}} |\nabla \phi|$ は、後述する生物学的駆動力 F_{bio} に依存した界面の法線方向への移動速度を決定するものである。この反応項は、自由エネルギー汎関数の変分から導かれる勾配流構造には厳密には基づいていないが、骨表面の法線方向移動速度を細胞活動に直接結び付けて制御するという本研究の目的に対し、数値的安定性と解釈性の両面から有効な近似である。

界面移動の駆動力となる生物学的駆動力 F_{bio} は、骨芽細胞による骨形成と破骨細胞による骨吸収の動的なバランスを考慮し、局所的な細胞密度を用いて以下のように定式化される。

$$F_{\text{bio}} = \dot{M}_f \rho_{\text{obl}} - \dot{M}_r \rho_{\text{ocl}} \quad (2.20)$$

ここで、 ρ_{obl} および ρ_{ocl} はそれぞれ骨芽細胞密度と破骨細胞密度を表し、 $\dot{M}_f$ および $\dot{M}_r$ は各細胞の活動に基づく単位密度あたりの骨形成能と骨吸収能を規定する係数である。この定式化により、 $F_{\text{bio}} > 0$ の領域では骨形成が優位となり界面が前進する一方で、 $F_{\text{bio}} < 0$ の領域では骨吸収が優位となり界面が後退する過程が表現される。

Phase Field 法を採用する主な利点は、複雑な骨梁構造において発生する結合や分離といったトポロジーの変化を、界面の再定義を必要とせず一貫して扱える点にある。加えて、 ϕ が全領域で連続かつ微分可能な関数として定義されるため、Level Set 法において特異点となり得る領域においても勾配を安定して算出できる。これにより、システム全体の微分可能性が担保され、自動微分等の技術を用いた微分可能シミュレータとしての構築が可能となる。

2.2.6 数値計算と微分可能性の担保

本項では、2.2.2 項から 2.2.5 項で導入した各物理・生物モデルを単一の計算グラフとして統合し、全体として微分可能な骨代謝シミュレータを構成するための、数値実装および自

動微分戦略について述べる．本研究では数値計算の基盤として JAX[36]を用い，骨代謝シミュレーションの計算過程全体で自動微分と GPU 上での並列計算を両立させた．JAX の逆モード自動微分により，細胞密度やシグナル分子濃度などの状態変数から評価指標に至る一連の計算を，連続的に微分可能な形式で記述している．

応力解析の中核をなす FEM においては，大規模自由度問題におけるメモリ消費が主要な課題となる．この問題に対処するため，本研究では全体剛性行列 K を明示的に構成しない行列フリーな Element-By-Element (EBE) 法を採用した．従来の FEM では K の非ゼロ要素の保持に膨大なメモリを要するが，EBE 法では要素剛性行列と変位ベクトルの積を要素単位で逐次計算することで，メモリ使用量を自由度数に対して線形なスケールに抑制している．近年，GPU 計算では演算性能よりもメモリ帯域幅が律速となる場合が多いため，大規模行列の走査を回避し，小規模なテンソル演算を高密度に実行する本手法は，実効的な計算効率の向上に寄与する．線形方程式 $Ku = f$ の求解には前処理付き共役勾配 (Preconditioned Conjugate Gradient; PCG) 法を用い，前処理として節点単位の局所剛性に基づくブロック対角近似のコレスキー分解を適用した．これにより，GPU 上での並列性を維持しつつ，複雑な幾何形状を含む解析においても収束性を改善し，順解析およびその勾配計算の安定性を確保している．なお，JAX が提供する共役勾配法実装を用い，その勾配計算は反復過程を展開しない陰関数微分 (implicit differentiation) に基づき定義される．

シグナル分子の空間分布を記述する反応拡散系については，数値的不安定性および高周波ノイズの抑制を目的として，時間方向の離散化に準陰解法を採用している．具体的には，減衰項を陰的に扱い，拡散項および生成項を陽的に評価することで，拡散支配的な系においても安定な時間発展を実現している．陽解法では拡散項に起因する厳しい Courant Friedrichs Lewy (CFL) 条件が生じるが，本定式化により比較的大きな時間ステップでの安定的な計算が可能となった．また，各シグナル分子の定常状態を効率的に求めるため，固定点反復に対して Anderson acceleration[37]を導入している．ここでも陰関数微分を用いることで，反復過程の計算履歴を保持することなく，収束後の平衡状態に対する勾配を定数メモリで評価している．

2.2.5 項で説明したように，骨界面の進化は Allen-Cahn 方程式によって記述する．界面移動の時間発展には陽的オイラー法を用い，主時間ステップ内で時間刻みを細分化したサブステップ計算を行うことで，界面の解像度と数値安定性を両立させている．この手法により，形状最適化過程におけるトポロジー変化を連続的に表現し，勾配に基づく更新を可能としている．

本研究における一連の計算過程は，設計変数 θ を入力，損失関数 L を出力とする以下のような合成関数として定式化される．

$$L = f_K \circ \dots \circ f_1(\theta) \quad (2.21)$$

これに対する勾配 $\nabla_{\theta}L$ は，逆モード自動微分に基づくベクトル・ヤコビアン積 (Vector-Jacobian Product; VJP) を通じて算出される．JAX は連鎖律に従い，出力側から入力側へと再帰的に VJP を適用することで，高次元な設計変数に対しても一度の逆伝播で効率的な勾配評価を実現する．本シミュレータは副作用を排除した純粋関数型プログラミングの設

計に基づいて構築されており, JIT コンパイルによる計算グラフ最適化と自動微分の整合性が保たれている.

細胞密度や濃度場など, 非負制約を伴う物理量に対しては, 順解析と勾配計算で異なる写像を用いる定式化を採用した. 順解析においては **ReLU** 関数を用いることで, 物理量が非負であるという制約を厳密に満たす. 一方, **ReLU** 関数は原点近傍で勾配が不連続となる上, 負の領域において勾配が 0 となるため, そのまま逆解析に適用すると勾配消失や最適化の停滞を招く懸念がある. そこで本研究では, 勾配計算においてのみ **ReLU** の代替として **Softplus** 関数の導関数に相当する代理勾配を定義した. これにより, 非負制約を維持しつつ勾配消失を回避し, 最適化過程の停滞を防いでいる.

また, 本研究では, 反応拡散系の定常解や構造解析における線形方程式の解を, 平衡状態として扱う. そのため, 反復計算の過程そのものを微分するのではなく, 陰関数定理に基づく陰関数微分を用いて勾配を評価する. 収束後の平衡状態を $f(x, y) = 0$ と定義するとき, 設計変数 x に対する解 y の勾配は以下のように評価される.

$$\frac{dy}{dx} = - \left(\frac{\partial f}{\partial y} \right)^{-1} \frac{\partial f}{\partial x} \quad (2.22)$$

この定式化により, 反復解法を陽に展開して自動微分する場合と比較して, GPU メモリ使用量を削減することができる. 特に, 本研究で扱う 3 次元骨代謝シミュレーションにおける逆解析では, このような定数メモリ特性が, 実用的な計算時間および問題規模を担保する上で有効である.

2.3 In-Silico Bone Biopsy の枠組みと逆解析

本研究で提案する ISBB は, 非侵襲的な臨床データから機械学習モデル等を用いて推定された骨評価指標を観測量とし, 微分可能骨代謝シミュレータ **D-Bone** の内部パラメータを逆解析により推定することで, 同時に患者個別の骨内部状態を推定・可視化する計算システムである.

2.1.3 項において, 観測量となる骨評価指標として BV/TV_{pred} および目標骨形成量 $\hat{V}_{\text{form}}$, 目標骨吸収量 $\hat{V}_{\text{res}}$ を導いた. しかし, 骨代謝システムにおいて, 骨量を一定に保つ定常状態の推定と, 代謝速度の再現は, 原理的に両立が困難な場合がある. 例えば, 骨形成が有意に亢進した骨内部状態を再現する場合, 最適化過程において骨形成量が骨吸収量を上回るため, 骨量は経時的に増加し続け, 定常状態への収束が阻害される. 一方, 骨量を厳密に一定に保つ制約を課した場合には, 骨形成・骨吸収速度の非対称性を十分に再現できない. このように, 骨量と代謝速度を同一の目的関数の下で同時に最適化することは, 数値的な困難さに加えて, モデルの物理的整合性の観点からも矛盾を生じさせる. そこで本研究では, Fig. 3 に示すような定常状態の推定と代謝動態パラメータの推定を分離し, 二段階の逆解析フレームワークを構築した.

第一段階では, 時間発展シミュレーションを通じて, 定常状態における BV/TV が機械学習モデルによる予測値と一致するよう, パラメータを逐次更新する. 本プロセスにおける目




Fig. 3 ISBB の推定プロセスの概要

関数 L_1 は、各時間ステップにおいて 1 ステップ時間発展させた後の骨形状に基づく $BV/TV(\phi_{t+1})$ と、2.1.3 項で推定された目標値 BV/TV_{pred} との二乗誤差として次式で定義される。

$$L_1(\theta) = (BV/TV(\phi_{t+1}) - BV/TV_{pred})^2 \quad (2.23)$$

ここで θ は推定対象のパラメータ集合である。各時間ステップにおいて順解析を実行した後、自動微分により得られた勾配 $\nabla_{\theta} L_1$ に基づき、確率的勾配降下法（Adam[38]）を用いて更新を行う。このプロセスを、誤差が許容値 ϵ 未満に収束するまで反復することで、臨床データと整合する患者固有の初期骨形状を推定する。なお、パラメータの非負制約を担保し、かつ広範囲な探索を可能とするため、最適化は対数空間上で行う。

第二段階では、第一段階で推定された定常状態を初期値とし、BTMs から得られた骨形成・吸収量を再現するためのパラメータ推定を行う。本プロセスでは、所定のシミュレーション期間における最終状態に基づいて評価される骨吸収量 $V_{res}(\theta)$ および骨形成量 $V_{form}(\theta)$ を用いる。目的関数 L_2 は、各代謝指標のオーダーの差異を正規化するため、目標値との正規化平均二乗誤差（Normalized MSE）として定義する。

$$L_2(\theta) = \frac{(V_{res}(\theta) - \hat{V}_{res})^2}{\hat{V}_{res}^2 + \eta} + \frac{(V_{form}(\theta) - \hat{V}_{form})^2}{\hat{V}_{form}^2 + \eta} \quad (2.24)$$

ここで $\hat{V}$ は目標値、 η は数値的安定化のための微小定数である。最適化戦略として、広域的な探索と局所的な収束性を両立させるハイブリッド戦略を採用する。まず初期段階では AdamW[39] を用い、定常状態から 15 日間の時間発展シミュレーションを行った後の最終状態における評価値に基づき最適化を複数回行う。その後 AdamW によって得られた、目的関数を最小化するパラメータと、それに対応する 15 日後の骨内部状態を初期値として、二次の勾配情報を活用する準ニュートン法である L-BFGS[40] へと切り替え、さらに 5 日間の時間発展後の評価値を対象とした最適化を複数回行う。この際、バックトラッキング・ラインサーチを併用することで、最適解近傍における精密な収束を実現する。

以上のように、統計的推定を担う機械学習モデルと、生理学的な整合性を担保する微分可




Fig. 4 海綿骨モデルの作成過程：(a) μ CT で撮像した断層画像と，それらを積層するイメージ．(b) 正規化後の初期骨形状 ϕ ．(c) 海綿骨モデルに対する MIL ファブリック楕円体と構造主軸座標系 (x', y', z') ．

能シミュレータ D-Bone を，性質の異なる 2 種類の骨評価指標を介して疎に結合させることで，非侵襲的な臨床データから患者個別の骨内部状態を推定することが可能となる．

2.4 μ CT を用いた海綿骨モデルの作成

本節では，本研究のシミュレーションにおいて初期骨形状として用いる，ブタ大腿骨由来の海綿骨モデルの作成方法について述べる．まず，Fig. 4a に示すように X 線 μ CT 装置 (inspeXio SMX-90CT plus, SHIMADZU) を用い，ブタ大腿骨頭内の海綿骨から連続断層画像を取得した．次に，Fig. 4b に示すように，得られた断層画像を積層した 3 次元画像データに対して Min-Max 正規化を施し，これを初期骨形状 ϕ と定義した．海綿骨モデルは，一辺 $24.0\mu\text{m}$ の立方体ボクセル要素により構成され，最大で 115^3voxels (2.76^3mm^3) の立方体領域とした．

本研究では，対象とする海綿骨構造が力学環境に適応した状態にあると仮定し，その構造異方性に基づいて負荷応力を決定した．具体的な手順として，まずモデルの各面の法線方向を x, y, z 軸とするモデル座標系を定義した．次いで，解析領域内の構造異方性を定量的に評価するため，MIL ファブリック楕円体[41]のファブリックテンソル $\mathbf{H}$ を算出し，その各主値に従って，構造主軸座標系 (x', y', z') を定義した (Fig. 4c)．ここでは，最大主値に対応する構造主軸を z' 軸に設定している．さらに，海綿骨モデルへ応力を均一に伝達させる目的で，モデルの全周囲を厚さ 4 voxels の均質な支持部材により囲い，当該部材の外表面に対して境界条件を課した．特に断りがない限り，大腿骨頭内の圧縮応力場を想定し，構造主軸座標系の z' 軸方向に -2.0MPa ， x' 軸および y' 軸方向にそれぞれ -1.0MPa の一樣圧縮応力を作用させ，シミュレーションを実施した．




Fig. 5 Heteroscedastic 回帰の予測値の散布図：左図は右大腿骨 BMD の Z スコアの真値を横軸に取り，学習済み Heteroscedastic 回帰モデルが推測した期待値を縦軸に取った散布図である．赤点線は真値と予測値が一致した場合の座標を示す．緑点は学習データに対する予測値であり，青点は評価データに対する予測値である．右図はモデルが予測した期待値と真値の誤差の絶対値を横軸に取り，モデルが予測した標準偏差を縦軸に取った散布図である．赤点線は回帰直線を示し，グラフ右上にその式を示す．また， ρ は Spearman 相関係数である．

第 3 章 結果

3.1 骨密度予測モデルの精度評価

3.1.1 各モデルの予測精度の比較

本節では，NHANES データセットを用いた大腿骨骨密度予測モデルの性能評価結果を示す．2.1.2 項 Table 2 で示した 7 種類の機械学習アルゴリズムについて，3 つの異なる乱数シードに基づき決定係数 R^2 の平均値および標準偏差を算出した．その結果，Table 3 に示す通り，Heteroscedastic 回帰モデルが $R^2 = 0.611 \pm 0.005$ と最も高い汎化性能を示した．

Table 3 各モデルの大腿骨 BMD 予測 R^2 決定係数比較

	Seed 1	Seed 2	Seed 3	Mean $\pm$ SD
線形回帰	0.592	0.609	0.574	0.592 $\pm$ 0.014
MLP	0.605	0.613	0.608	0.608 $\pm$ 0.003
1D CNN	0.594	0.609	0.587	0.597 $\pm$ 0.009
GBDT	0.601	0.620	0.605	0.609 $\pm$ 0.008
Heteroscedastic 回帰	0.606	0.617	0.610	0.611$\pm$0.005
Transformer	0.603	0.610	0.599	0.604 $\pm$ 0.005
条件付き拡散モデル	0.561	0.572	0.568	0.567 $\pm$ 0.005




Fig. 6 骨密度予測における重要因子の可視化：(a) 右脚大腿骨 BMD と各指標の相関係数の絶対値．(b) 各指標に対する学習済み Transformer の Attention 重み．

次に、基準とした線形回帰モデル ($R^2 = 0.592 \pm 0.014$) と比較すると、MLP, 1D CNN, Transformer, および GBDT といった非線形モデルはいずれも平均的に高い決定係数を示した．このことは臨床指標と骨密度の関係に非線形性が含まれていることを示唆している．一方で、これらの非線形モデルの間の性能差は比較的小さく、 R^2 の標準偏差も全体的に限定的であったことから、本タスクにおいては複雑なモデル構造が必須ではない可能性が示唆される．

予測値とともにその不確実性を出力する Heteroscedastic 回帰については、Fig. 5 に示す通り、絶対誤差と予測標準偏差の間に弱い正の相関が確認された ($\rho_{\text{spearman}} = 0.189$)．すなわち、予測誤差が大きいサンプルに対して、相対的に大きな不確実性が付与される傾向が認められ、この挙動はモデルの仮定と整合的である．

一方、条件付き拡散モデルは、全ての乱数シードにおいて他の手法よりも低い決定係数 ($R^2 = 0.567 \pm 0.005$) を示した．この傾向は本データセットにおいて当該モデルが十分な予測性能を発揮できなかったことを示している．

以上の結果から、NHANES のような実臨床データを用いた骨密度予測タスクにおいては、

分布生成を主目的とするモデルよりも、予測精度と不確実性推定を同時に最適化する回帰モデルが、安定した性能を示すことが確認された。

3.1.2 重要因子の特定と可視化

BMD 予測に寄与する臨床指標を特定するため、相関分析ならびに学習済み Transformer モデルにおける Attention 重みの解析を行った。Fig. 6a に示す相関分析の結果から、体重 (BMXWT)、身長 (BMXHT)、性別 (RIAGENDR)、およびクレアチニン (LBXSCR) が右脚大腿骨 BMD と比較的強い相関 ($|r| > 0.4$) を示すことが確認された。これらの指標はいずれも身体サイズや腎機能と関連する基本的な臨床指標であり、BMD との線形関係を通じて予測に寄与していると考えられる。

また、Fig. 6b に示す学習済み Transformer の Attention 重みの解析結果では、体重、身長、性別といった身体計測指標が高い重みを有する点は相関分析と共通しているものの、月齢 (RIDAGEMN) やアルブミン (LBXSAL) など、一部の生化学的指標にも相対的に高い Attention 重みが付与されていた。

一方で、骨吸収および骨形成といった骨代謝回転を反映する指標である uNTx (URXNT) や BAP (LBXBAP) などの BTMs は、相関分析および Attention 解析の双方において低順位にとどまった。この結果は、長期間にわたる骨代謝の累積的な結果を反映する指標である BMD の予測において、単一時点で測定された骨代謝回転指標の寄与が相対的に小さいことを示唆している。

以上の 3.1 節の結果を踏まえ、以降の実験では Heteroscedastic 回帰モデルを骨密度予測モデルとして用いる。

3.2 微分可能骨代謝シミュレータの順解析能力の検証

3.2.1 力学適応能の検証

骨は力学刺激に応答して吸収と形成を繰り返し、その形状や配向を変化させる力学適応能を有する。この適応過程では、局所的な応力・ひずみ状態に応じて骨代謝が空間的に制御され、結果として力学的に合理的な骨形態が形成される。そこで、微分可能骨代謝シミュレータ D-Bone の順解析における力学適応能を検証するため、形状の複雑さが異なる二つのモデルを対象として順解析を行い、力学条件に応じた形状変化が適切に再現されるかを確認した。

まず、単一骨梁スケールにおける検証として、荷重軸 (z 軸) に対して 30 度傾斜した円柱状の骨梁モデルを初期形状とし、z 軸方向の単軸圧縮を付与した。Fig. 7a を見ると、シミュレーション初期段階において、応力分布に基づき計算される力学刺激比 S_r が、上下から骨梁を圧縮している支持部材に対して鋭角を成す側の骨梁では高くなっており、鈍角を成す側では低くなっている。また、それに応じて 2.2.3 項に示した作用機序に基づき、鈍角側の骨梁では Sclerostin や RANKL の濃度が高まっている。Fig. 7b 中央の図を確認すると、このようなシグナル分子濃度分布に応じて、鈍角側の骨梁表面に破骨細胞が分布し、それ以外の領域には骨芽細胞が分布している様子が確認できる。




Fig. 7 一骨梁スケールにおける力学適応：(a) 1 ステップ目の生化学シグナル等の分布．左から力学刺激比 $S_r > 0.98$ の領域を水色で表現した図，Sclerostin 濃度 $C_{SCL} > 10.0 pM$ の領域を緑色で表現した図，RANKL 濃度 $C_{RANKL} > 4.0 \times 10^{-5} pM$ の領域を桃色で表現した図．(b) z 軸となす角が 30 度となるように傾けた骨梁に対して， z 軸方向に 0.1%ひずみが生じるよう強制変位を加えた場合の骨形状変化．

その結果，骨梁の傾斜角は時間の経過とともに縮小し，荷重軸方向へと再配向する挙動が確認された．このことから，本モデルにおいて，力学刺激に応じた局所的な代謝応答が，幾何学的形状変化として反映されることが示された．なお，単一骨梁スケールの実験におけるシミュレータの各パラメータ値を付録 S.1 の Table S2 に示す．

次に，組織スケールでの検証として，2.4 節で詳述した海綿骨モデルを用い，荷重方向の違いに伴う構造異方性の変化を評価した (Fig. 8)．同一の初期骨形状に対し，2.4 節に記した方法で z' 軸方向へ強く応力を与えたモデルと， z' 軸から 45 度傾斜した方向へ $-2.0 MPa$ ，それ以外の方向にそれぞれ $-1.0 MPa$ の一樣圧縮応力を作用させたモデルの，二つの荷重条件モデルを設定した．なお，本解析では MIL ファブリック楕円体の主軸長を $H_1 \geq H_2 \geq H_3$ と定義する．

z' 軸方向へ圧縮したケースでは，Fig. 8b に示すように，荷重軸と直交する $x'y'$ 平面方向の骨梁が減少し，荷重軸に沿った構造へと再構築される過程が観察された．また，Fig. 8a 右上に示す MIL ファブリック楕円体による定量評価では，初期状態で $H_1/H_3 = 1.352$ であった異方性比が，300 日後には $H_1/H_3 = 1.622$ まで増大した．これは，構造の異方性が荷重軸方向に強調されたことを示している．




Fig. 8 組織スケールにおける力学適応：(a) 中央上は z' 軸方向に負荷を与えた場合の 300 日後の骨形状．中央下は z' 軸に対して 45 度傾けた方向に負荷を与えた場合の 300 日後の骨形状．図中の白矢印は海綿骨モデルに対して主に応力負荷を与えた方向を示す．右は各条件における 0 日目の MIL ファブリック楕円体を水色，300 日目の楕円体を紫色で表現した図．(b) z' 軸方向に負荷を与えた場合の骨形状変化に着目し， $x'y'$ 平面方向の骨梁が途切れる様子を示した図．

一方，45 度傾斜方向へ圧縮したケースでは，Fig. 8a の下段に示すように，骨梁が荷重方向に対応して斜めに再配向する挙動が観察された．300 日後の異方性比は $H_1/H_3 = 1.581$ となり，併せて，ファブリック楕円体の主軸と z' 軸のなす角は 41.48 度へ変化した．この結果は，異方性の強さだけでなく，その主軸方向自体が荷重条件に応じて変化したことを示している．なお，組織スケールの実験におけるシミュレータの各パラメータ値を付録 S.1 の Table S1 に示す．また，断りがない限り，これ以降の実験ではこのパラメータ値を採用している．

以上より，D-Bone は，単一骨梁スケールから組織スケールに至るまで，荷重条件に応じた骨構造の再配向及び異方性変化を再現可能であることが確認された．




Fig. 9 骨代謝異常の再現 : (a) Control, Osteoporosis (Mechanical), Osteoporosis (Hormonal), Osteopetrosis の各モデルについて, 300 日間の骨形状変化を示す. なお, 図中の M は Mechanical, H は Hormonal を表す. (b) 各病態モデル及び Control について, シミュレーション開始から 50 日後の骨形状および破骨・骨芽細胞分布を可視化した図. 破骨細胞を赤, 骨芽細胞を青で表現している.

3.2.2 骨代謝異常の再現実験

本節では, D-Bone の順解析能力の検証の一環として, 力学的因子または生化学的因子の異常に起因する骨疾患の再現を検討した. 解析対象とした 300 日間に渡り BV/TV が安定していた Control モデルに対し, 以下の 3 つの病態モデルを構築し, それぞれの経時的変化を比較した.

まず, Control モデルに対し, 力学負荷を 1/3 とした Osteoporosis (Mechanical) モデル




Fig. 10 各病態モデルおよび **Control** について骨評価指標の経時変化をプロットした図：左上に BV/TV の経時変化，右上に Tb.Th の経時変化，左下に Ob.S/BS の経時変化，右下に Oc.S/BS の経時変化をプロットした．なお，図中の M は Mechanical，H は Hormonal を表す．

を用い，宇宙飛行士に見られる骨粗鬆症の再現を試みた．Fig. 9b の右側に示すように本モデルでは，Control と比較して骨梁表面において破骨細胞が広範囲に分布し，Fig. 10 左上に示すように骨吸収が急速に進行し，BV/TV が継続的に減少した．その結果，骨梁の断裂や消失が観察され，Fig. 9a に示すように，シミュレーション開始から 200 日目には元の骨構造が失われ，断片的な骨梁が残されるのみとなった．この挙動は，低負荷環境への力学適応が短時間で生じる過程を反映していると考えられる．

次に，閉経後骨粗鬆症等のホルモンバランス異常に起因する骨粗鬆症を想定し，RANKL の最低産生速度 c_{RANKL} を 0.0 pM/s から $4 \times 10^{-16} \text{ pM/s}$ へ上昇させた Osteoporosis (Hormonal) モデルを構築した．本モデルでは Fig. 9a に示すように，Osteoporosis (Mechanical) モデルで認められた急激な変化とは対照的に，骨梁全体が一様に緩やかに菲薄化する挙動が観察された．Fig. 10 左上の BV/TV を確認すると，Osteoporosis (Hormonal) モデルは 130 日目前後を境に，BV/TV が減少から緩やかな増加に転じている．また，Oc.S/BS や Ob.S/BS も 150 日目以降は比較的安定した推移を辿っている．このような現象は，生化学的因子の変調が緩やかな骨量減少をもたらし，最終的に新たな代謝平衡状態へと移行する病態を再現していると解釈できる．

さらに，大理石骨病 (Osteopetrosis) の一形態として，破骨細胞は存在するものの，酸分

泌不全により骨基質を溶解できない病態を想定し、2.2.5 項で述べた Phase Field 法における界面後退速度 $\dot{M}_r$ を Control モデルの 1/3 に低下させた Osteopetrosis モデルを構築した。本モデルでは、Fig. 9b に示すように破骨細胞が骨表面に局在しているにもかかわらず骨吸収が抑制され、相対的に骨形成が優位となった結果、Fig. 9a に示すように骨髓空間の狭小化が観察された。Fig. 10 を確認すると、BV/TV は単調に増加しているにもかかわらず、骨梁幅 (Trabecular thickness; Tb.Th) は比較的变化が小さいことが分かる。これは、骨吸収不全型の大理石骨病において特徴的にみられる、海綿骨の吸収不全と残存、およびそれに伴う骨リモデリング不全という病態[42]を再現していると考えられる。

以上の結果は、生化学因子に起因する骨減少と比較して、力学因子に起因する骨減少が短期間かつ局所的に進行するという先行研究の知見[43]と整合している。このことは、D-Bone が多様な骨代謝疾患の生理学的機序を適切にモデル化可能であることを示している。

3.3 微分可能骨代謝シミュレータの逆解析能力の検証

本節では、微分可能骨代謝シミュレータ D-Bone の自動微分によって得られる勾配情報を用いた逆解析アルゴリズムの有効性を検証し、それを通じて D-Bone の微分可能性が有効であることを示す。検証には双子実験を採用し、既知のパラメータセットから生成した骨形状および代謝指標を観測データとみなし、これらを目標値とした逆解析により元のパラメータを推定した。この双子実験において、逆解析による推定値が真値に精度よく収束した場合、提案アルゴリズムの有効性が示されたものとする。

逆解析の対象として、骨芽細胞および破骨細胞の分化・アポトーシス反応の活性を規定する 4 種類のスケーリング係数、すなわち 2.2.4 項の 2.13 式および 2.14 式中の $k_{\text{diff,Obl}}$, $k_{\text{diff,Ocl}}$, $k_{\text{apop,Obl}}$, $k_{\text{apop,Ocl}}$ を推定対象とした。これらのパラメータを対象としたのは、パラメータ値の変動が破骨・骨芽細胞の活動に直結し、その影響を解釈しやすいためである。また、その他の物理的および生化学的パラメータについては付録 S.1 の Table S1 に示す値に固定した。

D-Bone が多様な代謝条件においても逆解析能力を有することを検証するために、目標状態として、骨リモデリングが定常的に推移する Normal 状態と、骨吸収が優位となる骨減少状態の Abnormal 状態の 2 条件を設けた。各条件について順解析を行い、得られた観測結果を目標値として設定した。観測データには、初期状態から 15 日先までのスカラー時系列データとして BV/TV, Ob.S/BS, Oc.S/BS, 骨形成量 V_{form} , 骨吸収量 V_{res} を用い、これに加えて終端ステップにおける骨形状 ϕ を含めた。骨形状の比較には最適輸送損失を導入し、時系列データに基づく損失と組み合わせた目的関数を定義した。逆解析では、この目的関数を最小化するようパラメータ最適化を行った。なお、この目的関数の値を $k_{\text{diff,Obl}}$, $k_{\text{apop,Obl}}$ の 2 変数に対してプロットした図を Fig. 12 に示す。

手法の比較として、自動微分により得られる勾配情報を利用する AdamW と、勾配を必要としない Nelder-Mead (NM) 法を適用した。勾配ベース最適化アルゴリズムとして AdamW を選択した理由は、勾配計算過程で生じ得るスパイク状ノイズに対する頑健性を考慮したためである。どちらの手法においても、初期値は真値から最大で $\pm 20\%$ の範囲でラ




Fig. 11 双子実験の結果：左図は最適化 Step 数に対する目的関数の値をプロットした片対数グラフである．右図は最適化後の各パラメータの値の相対誤差の絶対値をプロットした棒グラフである．上段は骨量が定常的に推移する Normal 状態，下段は骨量が継続的に減少する Abnormal 状態における検証である．それぞれのグラフにおいて、青が AdamW、赤が Nelder-Mead 法を示す．

ンダムに乖離させ、異なる 3 つの乱数シードを用いて各 150 ステップの最適化を実施した．最終的な推定結果としては、全ステップ中で目的関数が最小となった時点のパラメータを採用した．

Fig. 11 に、Normal および Abnormal の各条件における目的関数の推移と、真値に対する推定パラメータの相対誤差の絶対値を示す．目的関数の収束挙動に着目すると、初期ステップにおける損失の減少速度については NM 法と AdamW の間で顕著な差は認められなかった．一方、収束後に到達した目的関数の値を比較すると、どちらの条件においても AdamW を用いた場合の方が低い値を示した．

次に、パラメータの推定精度を比較すると、Normal 条件の $k_{\text{diff.Ocl}}$ の推定において NM 法が AdamW より僅かに低い平均誤差を示した点を除き、ほぼすべてのパラメータにおいて AdamW は NM 法よりも高い推定精度を達成した．特に NM 法では、推定精度の初期値依存性が認められ、試行間で推定結果の標準偏差が増大する傾向が観察された．これに対し、AdamW を用いた勾配ベース手法では、すべてのパラメータが安定して低い誤差範囲内に収束し、標準偏差も NM 法と比較して抑制された．

以上より、骨代謝システムの逆解析において、D-Bone の微分可能性を活用した勾配ベー




Fig. 12 Loss ランドスケープと最適化アルゴリズムごとのパラメータ軌跡：図は $k_{\text{diff,obl}}$, $k_{\text{apop,obl}}$ の 2 変数を推定対象とした際の目的関数の値を、パラメータの真値に対して $\pm 20\%$ の範囲で可視化したものである。色が黄に近いほど目的関数の値が大きく、紺に近いほど小さいことを示す。推定対象のパラメータの真値を黄の星マークで示す。また、上記の条件における AdamW によって更新されたパラメータの軌跡を赤、Nelder-Mead 法によるものを青でプロットした。この時、パラメータの初期値を丸、最終値を正方形のマークで表す。

スの最適化は、複雑なパラメータ空間においても安定したパラメータの再現と、観測された骨内部状態の推定を可能とすることが確認された。この結果は、提案する微分可能骨代謝シミュレータが逆解析能力を有していることを示している。

3.4 In-Silico Bone Biopsy の妥当性評価

3.4.1 臨床データによるケーススタディ

これまで独立に実施してきた、機械学習による骨密度予測能力と、D-Bone の順解析・逆解析能力の検証結果を踏まえ、本項では 2.3 節で述べたように両者を統合した ISBB システムの有効性を実証するため、実際の臨床データを用いたケーススタディを行う。本検証では、NHANES データセットの評価用データから特徴的な代謝動態を有する被験者サンプルを

抽出し、非侵襲な指標のみから個別の骨内部状態および、その将来的な経時変化を推定する事を目的とする。

被験者サンプルの選定にあたり、まず各被験者の骨状態を臨床的基準に基づいて分類するため、世界保健機関（WHO）の定義に準拠し、右大腿骨骨密度（ BMD_{true} ）を用いて次式により T スコアを算出した[44].

$$T = \frac{BMD_{\text{true}} - \mu_{\text{YAM}}}{\sigma_{\text{YAM}}} \quad (3.1)$$

ここで、 μ_{YAM} および σ_{YAM} は、2.2.1 項で詳述したデータセットのうち、20 歳から 29 歳の若年成人群（Young Adult Mean; YAM）から得られた基準平均値および標準偏差である。

臨床診断の基準では $T < -2.5$ が骨粗鬆症と定義されるが、本研究の評価用データにおいて当該基準に合致するサンプル数は限定的であった。そのため、十分な母集団を確保しつつ、多様な骨代謝バランスを検証可能とする目的から、本項では $T < -2.2$ の範囲まで対象を広げて検証用サンプルを抽出した。

サンプルの選定にあたっては、骨量と代謝状態のバランスが異なる 6 つのグループを設定した。具体的には、評価用データから BMD_{true} に基づく T スコアが標準的な Normal 群（ $T \approx 0$ ）、骨粗鬆症に近い低骨量群である Abnormal 群（ $T \leq -2.2$ ）を抽出した。さらに各群に対し、BTMs のうち骨形成マーカーである BAP と骨吸収マーカーである uNTx の Z スコアの差分を代謝バランスの指標 $\Delta Z = Z_{\text{BAP}} - Z_{\text{uNTx}}$ と定義し、骨形成が相対的に優位な状態（ $\Delta Z \approx 1$ ）、骨代謝のバランスが維持されている状態（ $\Delta Z \approx 0$ ）、および骨吸収が相対的に優位な状態（ $\Delta Z \approx -1$ ）の 3 パターンに該当するサンプルをそれぞれ抽出した。以上の手続きにより選定された計 6 名の被験者サンプルを対象として、ISBB の推定能力を検証する。また、各サンプルの推定結果を含む詳細を Table 4 に示す。

Table 4 各サンプルの推定結果を含む詳細データ

SEQN	12606	15939	15275	4868	6107	4905
T-Score	0.141	-0.215	-0.255	-2.403	-2.591	-2.235
$BMD_{\text{true}} [g/cm^2]$	1.237	1.184	1.178	0.858	0.830	0.883
$BMD_{\text{pred}} [g/cm^2]$	1.222	1.165	1.203	0.884	0.892	0.941
BAP [$\mu g/L$]	24.5	7.7	20.0	26.7	14.4	25.1
uNTx [nmol BCE]	243.0	97.0	1596.0	313.0	339.0	2239.0
BV/TV [%]	31.65	29.85	31.06	21.00	21.24	22.78
$\hat{V}_{\text{form}} [10^{-3}mm^3]$	3.084	2.403	2.993	4.435	3.916	4.171
$\hat{V}_{\text{res}} [10^{-3}mm^3]$	2.958	2.337	3.717	1.787	1.851	2.870

なお、表中の $\hat{V}_{\text{form}}$ および $\hat{V}_{\text{res}}$ は 2.1.3 項に示した方法により算出されたものである。

Fig. 13 に、選定された 6 パターンの被験者における推定結果を示す。まず、逆解析の第一段階において推定された初期状態の骨形状および BV/TV に着目すると、Normal 群と




Fig. 13 ISBB の検証結果：(a) 各 SEQN から推定された初期骨形状と、その 100 日後の様子を可視化した図。(b) 左から、各 SEQN から推定された骨内部状態をもとに 100 日間時間発展させた際の BV/TV 変化をプロットした図、各 SEQN の実際の BMD の Z スコア Z_{BMD} と、骨密度予測モデルを用いて予測された $\hat{Z}_{\text{BMD}}$ の散布図、各 SEQN の Z_{BAP} と Z_{uNTx} の散布図。なお、図中の赤点線は横軸の指標と縦軸の指標が同じ値であることを示す。

Abnormal 群が明確に分離されている。特に、Fig. 13a の 0 日目の骨形状を比較すると、Normal 群に該当する左側に対し、Abnormal 群である右側の海綿骨形状は全体的に骨梁が細くなっている事が分かる。これは、血清データや身体計測値といった統計的なマクロ情報から推定された骨密度を、数理モデルを用いた逆解析を介する事で、個別の患者における海綿骨微細構造という三次元的なマイクロ情報へと写像し、生理的整合性をもって推定しうることを示唆している。

次に、推定されたパラメータに基づく 100 日間の経時的な BV/TV 変化について述べる。まず、Fig. 13b 右の図は Z_{BAP} と Z_{uNTx} をプロットした散布図である。この図において $\Delta Z = 0$ を示す赤点線より上のサンプルは骨吸収指標が相対的に優位であり、下にあるサンプルは

骨形成指標が相対的に優位であることを示す。その上で、Fig. 13b 左に示す BV/TV の経時変化をプロットしたグラフを見ると、骨形成指標が相対的に高いサンプル (SEQN: 12606, 4868) では BV/TV が上昇し、両者のバランスが均衡しているサンプル (SEQN: 15939, 6107) では概ね定常状態を維持する結果となった。一方で、骨吸収が優位なサンプル (SEQN: 15275, 4905) では BV/TV が継続的に減少する挙動を示した。これらの結果は、現在の骨量という静的な情報に加え、臨床検査値に含まれる BTMs から算出された目標骨形成量 $\hat{v}_{\text{form}}$ および目標骨吸収量 $\hat{v}_{\text{res}}$ という動的な指標が、将来の骨構造変化の予測に対し有効に機能していることを示す。

以上の検証結果から、ISBB は臨床現場で得られる非侵襲なデータを用いながら、従来の DXA 法等の静的な骨量評価では捉えきれない、生体内部の動的な代謝不均衡を再現しうることが示された。これは、機械学習による個別データへの適応能力と、数理モデルによる生理学的解釈性を融合させた Gray-box アプローチの優位性を裏付けるものである。

3.4.2 骨内部状態の可視化による詳細解析

本項では、ISBB の臨床応用における大きな利点の一つである解釈可能性の高さを実証するため、前項で選定した代表サンプルのうち、対照的な骨量および代謝動態を示した 2 名 (SEQN: 12606, 4905) を対象として、骨内部における生化学シグナルおよび細胞密度の空間分布を詳細に解析する。Fig. 14 に、各サンプルの解析領域における 0 日目および 100 日目の骨形状 ϕ 、ならびに 0 日目における力学・生化学状態の分布を示す。

まず、骨密度が正常かつ骨形成優位なサンプル 12606 の経時変化に着目すると、0 日目から 100 日目にかけて、荷重方向に沿った骨梁配向に伴い、骨梁壁面の空隙で骨形成が進行し、構造の連結性が向上する過程が確認できる。このとき力学刺激比 S_r は、骨梁表面の一部で高く、骨内部で低いという明確な勾配を有している。これに呼応して、骨形成抑制因子である Sclerostin の濃度 C_{SCL} は骨内部で高濃度となる一方、骨表面付近では低濃度に維持されており、骨芽細胞による骨形成活動を許容する局所的な場が形成されている。実際に、骨芽細胞密度 ρ_{obl} の分布を確認すると、骨表面、特に荷重方向に配向した骨梁壁面の空隙近傍において高い値を示している。この ρ_{obl} の分布は骨表面において、 C_{SCL} の濃度分布に対して負の相関を示しており、このサンプルでは骨吸収とのカップリングよりも、力学環境に応じたモデリング作用が骨形成の支配的な要因となっていることが示唆される。

一方、骨量が少なく骨吸収優位なサンプル 4905 では、100 日目にかけて骨梁の全体的な菲薄化が観察される。本サンプルは ρ_{obl} および破骨細胞密度 ρ_{ocl} の双方が 12606 と比較して相対的に高く、高回転型の骨代謝状態にあることが可視化されている。これは Fig. 13b 右の図に示すように、逆解析の境界条件の算出に用いた BTMs の Z スコアが高い事と整合する。シグナル分布においては、力学刺激比 S_r が低い領域では C_{SCL} の値が高くなっており、また C_{SCL} と C_{RANKL} の分布に空間的な対応関係が確認できる。これは、低負荷領域において RANKL 濃度が高まり、破骨細胞の分化が促進されるという骨吸収の生理学的機序を表現したものと言える。また、 ρ_{obl} の分布は、破骨細胞による吸収過程で放出される MDGF 濃度 C_{MDGF} の分布と相関を示している。これは本サンプルの骨形成において、骨吸収が生じた部位にて二次的に骨形成が促されるカップリング作用が支配的であることを示唆している。




Fig. 14 SEQN 12606, 4905 について、骨形状、力学刺激比、シグナル分子濃度、細胞密度の断面を可視化した図：半透明の橙色平面で表している海綿骨モデルの立方体を等分する xy 平面における 0 日目の骨形状 ϕ (Day 0), 100 日目の骨形状 ϕ (Day 100), 0 日目の力学刺激比 S_r , Sclerostin 濃度 C_{SCL} [pM], RANKL 濃度 C_{RANKL} [pM], MDGF 濃度 C_{MDGF} [pM], 骨芽細胞密度 ρ_{obl} [$1/mm^3$] および破骨細胞密度 ρ_{ocl} [$1/mm^3$] を可視化した。なお ϕ 以外の図中の白線は、骨界面 ($\phi = 0.5$) をプロットしたものである。

以上の解析結果から、ISBB は、マクロな臨床指標の背後に内在する骨量変化の要因を、力学刺激、生化学シグナル、および細胞活動の連鎖からなる骨リモデリング過程として表現し、可視化可能であると示された。本手法は、DXA 法による静的な骨密度評価や、全身の代謝回転の平均値を示す BTMs では捉えきれない、局所における骨代謝バランスの不均衡を、その発生機序に即して表現するものである。特に、骨形成に対するモデリングおよびカップリングの寄与度のサンプル間差を表現できた点は、本システムが個別の病態形成過程を細胞レベルの動態から解析可能であることを示唆する。

第 4 章 考察

4.1 In-Silico Bone Biopsy の実現に向けた基盤の確立

本研究では、統計的・帰納的アプローチである機械学習と、演繹的・機構論的アプローチである数理シミュレーションを相補的に統合した計算システム In-Silico Bone Biopsy を提案した。

機械学習モデルの構築において、Heteroscedastic 回帰が有効であった点は実臨床応用の観点から重要である。NHANES のような大規模疫学データは、測定誤差や未観測の交絡因子、さらには集団の異質性を内包している。単一の点推定ではなく、予測値とともにその不確実性を同時に出力することで、後段の逆解析において境界条件の信頼性を定量的に評価することが可能となる。

一方、Heteroscedastic 回帰と同じ確率的生成モデルである条件付き拡散モデルは、Table 3 に示す検証結果において、全手法の中で最も低い決定係数を示した。この要因については、拡散モデルの学習における、汎化と過学習のトレードオフから説明可能である。Bonnaire らの研究[45]によれば、拡散モデルの学習過程には、高品質なサンプル生成が可能となる汎化開始時刻 τ_{gen} と、訓練データの標本再現が始まる時刻 τ_{mem} という 2 つのタイミングが存在する。このうち、 τ_{mem} は訓練データ数 n に対して線形に変化する特性を持つため、 n が増えるほど、訓練データへの過学習を避けつつ、汎化性能を維持できる学習時間の範囲が拡大する。本研究で用いた NHANES データセットは、拡散モデルの表現力に対して相対的に小規模なデータサイズであった可能性が高く、そのために、モデルがデータ全体の構造を学習し、十分な汎化性能を獲得する前に、過学習が進行してしまったと推測される。

また、Fig. 6 に示す Transformer における Attention 解析の結果は、相関分析のような単変量・線形な寄与評価では捉えきれない多変量間の依存関係を示唆している。これは、テーブルデータにおいて Transformer が変数間の高次な相互作用を抽出する能力に長けているという知見[46]とも整合しており、相関分析では上位に現れなかった月齢やアルブミンが Attention において高い重みを有していたことは、これらの指標が他の変数と組み合わせることで骨密度の説明力に寄与していることを示唆している。特にアルブミンは、生体内のタンパク質の大部分を占める栄養状態の指標であると同時に、血中カルシウムと結合し、輸送する役割を持つ。骨基質の主成分がタンパク質のコラーゲンである点や、アルブミンがミネラルバランスに関与する生理的背景を考慮すれば、アルブミンは栄養や代謝の複合的文脈において重要な情報を保持していると考えられる。本解析結果は、こうした生化学的な機序に基づく変数間の相互作用を、Transformer が適切に捉えている可能性を示している。

D-Bone の順解析能力に関する検証から、骨代謝における力学因子と生化学因子の相互作用を、提案した数理モデルによって適切に記述できることが示された。単一骨梁スケールの実験では、Fig. 7 に示すように、力学刺激の空間的不均衡に応答して Sclerostin や RANKL などのシグナル分子が濃度勾配を形成し、それが破骨細胞および骨芽細胞密度の分布変化を介して骨梁の再配向を導く一連の適応過程が再現された。また、病態再現実験においては、力学的負荷の低下と生化学因子の変調という二つの異なる骨粗鬆症発症機序を比較した

結果、先行研究で報告されている知見と整合する挙動が確認された。さらに、骨吸収不全型大理石骨病に特徴的な海綿骨の吸収不全や、それに伴う骨リモデリングの停滞現象も再現され、本モデルが多様な骨疾患の病態を統一的に表現し得ることが示された。

次に、本研究で構築した **D-Bone** と、その基盤となった先行研究の **V-Bone** との比較を通じて、本手法の特性を考察する。**V-Bone** は、細胞個々の挙動を追跡する離散的なエージェントベースモデルを採用しており、破骨細胞の走化性、確率的な分化・アポトーシス過程といった細胞単位の事象を詳細に記述できるという利点を有していた。一方、**D-Bone** では、細胞分布および骨形状を連続値の場として定義し、その時間発展を偏微分方程式系に基づいて記述する枠組みを採用している。この連続体近似への移行は、本研究の目的であるモデル全体の微分可能性の確保に不可欠である一方、物理現象の表現様式においては一部離散モデルとは異なる特性をもたらす。

例えば、離散モデルでは、骨梁の菲薄化に伴う応力伝達の遮断や骨梁の断裂といった不連続な物理現象を、構造変化として直接的に扱うことが可能である。これに対し、**Phase Field** 法を用いる **D-Bone** では、骨界面が有限幅をもつ遷移層として表現され、トポロジー変化は自由エネルギー最小化過程として連続的に進行する。その結果、骨梁が物理的に破綻する瞬間の挙動や、クラック発生に起因する不安定性の表現に関しては、離散モデルの方が優位であると考えられる。

また、双子実験 (**Fig. 11**) において勾配ベース手法である **AdamW** が勾配フリー手法の **NM** 法を上回る精度を示したことは、複雑なシステムにおいて、自動微分による勾配の伝播が、解の探索効率と推定の頑健性を向上させるという知見[47]と整合している。本解析では4種類のパラメータを同時に推定対象としているが、そのうちの2変数に着目して目的関数の形状を可視化した結果を **Fig. 12** に示す。この結果によれば、目的関数の広域的な凸性は維持されている一方で、パラメータ間の強い相関に起因する谷状の構造と、微視的なノイズが確認された。**Nelder-Mead** 法では、これら目的関数の不規則な地形やパラメータ間の干渉が収束の阻害要因となったのに対し、**AdamW** は勾配情報とモーメント成分によってノイズの影響を抑制し、相関の強い多次元空間においても安定した探索を実現したことが、高い推定精度に繋がったと考えられる。

最後に3.4節では、臨床データから機械学習を通じて患者個別の境界条件を推定し、これらのマクロな骨評価指標から、逆解析によって **Fig. 13** に示すような3次元的な海綿骨形状を含む骨内部状態を推定し、さらに経時変化を予測した。それに伴い、**Fig. 14** に示すように力学状態、シグナル分子濃度分布、細胞密度分布を含む、詳細な骨内部状態を再現できたことは、本システムが臨床における非侵襲性と情報量のトレードオフという課題を克服しうる **Gray-box** アプローチとして機能することを示唆しており、計算機上での骨生検 (**In-Silico Bone Biopsy**) としての潜在的な実用性を備えていることを実証するものである。

4.2 今後の課題

本研究は **ISBB** の概念実証としての位置づけであり、実用化に向けては生理・数理・実装の各面で克服すべき課題が存在する。

4.2.1 生理的課題

第一に生理的課題として、初期形状にブタ大腿骨の μ CT データを用いている点が挙げられる。本研究では、形状そのものの幾何学的精度よりも、荷重応答や代謝ダイナミクスの再現性に主眼を置いたため、種差の影響は無次元化や正規化によって最小化できると仮定している。しかし一方で、ヒトとブタでは骨組成や密度分布、機械的特性に差異が存在することが報告されている[48]。このような特徴の差異が、逆解析におけるパラメータの収束値や推定精度に与える影響については、HR-pQCT 等を用いて取得したヒト由来の骨微細構造データを初期骨形状として用いた、さらなる検証が必要である。

また、本研究の臨床データを用いた検証が 6 例のケーススタディに留まっており、手法の汎化性能を保証するには至っていない点も課題である。さらに、現状では BMD や BTMs 以外の真の内部状態を参照する教師データが存在しないため、推定された破骨・骨芽細胞密度分布やシグナル分子濃度分布がどこまで真値に近いかを評価できていない。したがって、本研究の結果は現時点では、臨床指標と統合的な内部状態の解釈案を提示しているという段階に留まる。

これらの課題を解決し、システムの臨床的信頼性を確立するためには、既存の臨床指標や大規模コホートなどの独立した実測データとの対応関係を定量的に検証していくことが求められる。例えば、骨生検データ、あるいは骨粗鬆症治療薬の投与前後における縦断的追跡データと ISBB の出力を比較することにより、推定された骨内部状態が生物学的実態とどの程度整合しているかを定量的に評価できる。また、DXA 画像から非侵襲的に取得可能な海綿骨構造指標 (Trabecular Bone Score; TBS) を骨質評価の参照指標として活用する事も有効なアプローチである[49]。これにより、本システムで推定された骨微細構造などの骨質情報と、臨床データ間の整合性を、より容易かつ定量的に比較検証できると期待される。

4.2.2 数理的課題

第二に数理的課題として、シミュレータの数値的安定性と物理的整合性の両立に関する点が挙げられる。本研究で骨形状の表現に用いている Allen-Cahn 方程式には、界面エネルギーを最小化しようとする表面張力的な作用が含まれている[34]。この拡散項の影響力はシミュレータ全体の骨量に依存して相対的に変化し、特に骨量が少ない低密度領域においては、生物学的な駆動力に対して拡散項の寄与が支配的となる傾向がある。その結果、数値計算上の要請により、本来の代謝バランス以上に骨量を減少させるような非生理的な偏りが生じ得ることが予備検討において示唆された。このような数理モデルの定式化に内在する偏りを、物理的整合性を保ちつつ抑制することは、シミュレーションの信頼性を担保する上で重要な課題である。

この課題を解決するためには Allen-Cahn 方程式のモビリティ係数 M を小さくしつつ、シミュレータが安定して動作するパラメータ値の探索も重要であるが、例えば、シミュレーション中の骨量変化に基づき、動的に代謝バランスを補正し、非生理的な偏りを打ち消すようなアルゴリズムの導入も考えられる。

4.2.3 実装上の課題

最後に、社会実装を見据えた際の実装面での課題として、計算コストとアクセシビリティの両立が挙げられる。本手法は、3次元ボクセル有限要素法に基づく力学解析と、反応拡散方程式による骨代謝モデルを時間発展的に連成させているため、本質的に計算負荷が高い。本研究では、GPUによる並列計算を前提とした実装最適化を行うことで、研究用途や限定的な臨床応用を想定した条件下では、実用的な時間内での解析が可能である（付録 S.4）。一方で、一般的な医療端末が備える計算資源を前提とした場合、依然として計算要求は高く、広範な臨床現場への導入には課題が残る。

このような、計算コストとアクセシビリティの両立という実務的制約に対しては、物理的整合性を担保する数理モデルと、計算効率に優れたサロゲートモデルを組み合わせた二層的な運用が解決策として挙げられる。すなわち、詳細な解析や研究用途においては D-Bone を含む ISBB システムを用い、一方で臨床スクリーニングや大規模解析においては、その挙動を近似するサロゲートモデルを用いるという役割分担である。サロゲートモデルを構築する際には、出力値のみならず、自動微分によって得られる勾配情報も学習対象とする **gradient-enhanced surrogate modeling** の枠組みを導入することで、限られた学習サンプル数からでも効率的に物理的挙動を模倣できる[50]。これにより、利用可能な時間や計算資源に応じて、数理モデルとサロゲートモデルを使い分ける柔軟な運用が可能となり、広範な臨床現場への展開に向けた障壁を低減できると考えられる。

4.3 In-Silico Bone Biopsy の有用性

骨疾患において骨の脆弱性は骨量のみで規定されるわけではなく、骨代謝回転亢進や石灰化障害など、患者背景に依存した様々な異常に応じた微細構造と材料特性の変化の結果として決定される。このような骨内部状態の異常は BMD や BTMs などの平均化されたマクロ評価では捉えることができない。実臨床における骨生検は、細胞動態、石灰化度、微細構造等の骨内部状態を直接観察できるだけでなく、テトラサイクリンなどによる標識法を用いることで静的な骨組織の観察から、骨形成速度や吸収速度等の代謝動態の評価も可能である。しかしながら、このような病態解釈性の利点があるにも関わらず、骨生検はその侵襲度の高さから実際に骨代謝疾患の診断に用いられる例は限られている。近年、HR-pQCT の開発により、ヒト末梢骨の高解像度の撮像が可能となった。これにより、従来の臨床 CT 検査によるマクロ評価では不可能であった、ヒトの骨微細構造の *in-vivo* 解析が可能となった。しかし、静的な微細構造情報は、多様な骨内部状態の一部にすぎず、動的に変化する患者の病態の理解には不十分である。

本研究で提案する ISBB は、Fig. 13, Fig. 14 に示したように、非侵襲的な採血データやデモグラフィック情報等に基づき、骨微細構造、力学状態、骨代謝シグナル動態、および、細胞動態を予測することが可能である。これは、骨生検における病態の解釈性を、非侵襲に実現することに他ならず、本研究では、この ISBB を実現するための基盤を確立した。今後、シミュレータの数理モデルを拡張し、提供可能な内部情報が増えるほど ISBB の価値はさらに高まる。例えば、腎疾患による腎機能低下は、骨の石灰化障害を引き起こし、結果的

に骨脆弱性を招く。類骨石灰化モデルをシミュレータに導入することで、採血で取得される腎機能情報を反映した石灰化障害が再現され、骨軟化症の診断や治療へと繋げることができる。また、骨損傷は重要な材料特性の一つである。荷重に伴う損傷発展をシミュレータに導入することで、運動習慣などのライフスタイルデータを反映した骨損傷状態を表現できるようになり、運動療法の個別化が可能となる。さらに、ISBB では Fig. 13 に示すように、ある時点における非侵襲的臨床データに基づき逆解析を行うことで、患者個別のパラメータ値を取得可能であり、さらにこのパラメータ値を用いて順解析を実施することにより、将来の骨内部状態の予測を可能とする。これは、実臨床における骨生検では実現できない *in-silico* アプローチの最大の利点の一つであり、病態に基づき治療戦略を検証するための予測技術として、ISBB を活用できる可能性を示している。

4.4 将来の展望

以上の議論を踏まえ、ISBB を臨床的に意義のあるシステムへと発展させるための今後の展望について述べる。

まず、シミュレーションの初期骨形状の課題に対する更なる発展として、近年注目されている三次元拡散モデルの導入が考えられる。デモグラフィック情報等の条件変数 c に基づく、初期骨形状 ϕ の条件付き確率分布 $p(\phi|c)$ を学習することで、ヒト特有の骨微細構造の特徴を統計的に反映した、患者個別の初期骨形状を生成することが考えられる [23], [51], [52]。さらにこれを前提として、数理モデルの数値的安定性や境界条件推定に伴う不確実性については、システム全体を確率論的に再定式化することが有効な手法である [53]。具体的には、ISBB の順解析モデル $f_{ISBB}(\phi)$ の出力を、観測データ y の期待値とし、Heteroscedastic 回帰モデルから得られる予測分散 $\Sigma(c)$ を、観測ノイズ分散とすることで以下の尤度関数を定義する。

$$p(y|\phi, c) = \mathcal{N}(y|f_{ISBB}(\phi), \Sigma(c)) \quad (4.1)$$

このとき、前述の初期骨形状生成モデルを事前分布 $p(\phi|c)$ として導入することで、以下の式により、推定結果を事後分布として扱うベイズ的推論の枠組みが構築できる。

$$p(\phi|y, c) \propto p(y|\phi, c)p(\phi|c) \quad (4.2)$$

このような定式化により、入力データやモデル近似に起因する不確実性を信頼区間として定量化でき、診断や意思決定における判断根拠の透明性を高めることが可能となる。

さらに長期的な展望としては、4.3 節で述べたように、骨代謝を単一臓器の現象としてではなく、全身の恒常性維持機構を構成する要素の一つとして位置付ける視点が重要となる。この観点に基づき、腎機能、内分泌系、免疫系との相互作用を考慮した多臓器連関モデルへと ISBB を拡張することで、続発性骨粗鬆症のように多因子が関与する疾患に対しても、個別患者における病態形成メカニズムの理解が可能になると考えられる。とりわけ本システムは MIMIC-IV 等の大規模臨床データセットに含まれる生体時系列データの利用を想定し

て設計されており、既存のデータ駆動型多臓器連関モデルとの高い親和性を有する。

この特性を踏まえた発展形として、各臓器の機能的役割を LLM に割り当てて多臓器連関を記述する既存研究[54]の枠組みにおいて、ISBB を、骨代謝を担う Agent として統合することが考えられる。具体的には、大規模視覚言語モデルを基盤としながら、電子カルテに由来するテキスト情報、CT 等の医用画像情報、および生体時系列データを同一表現空間にトークナイズして統合し、Transformer への入力とする構成が想定される。さらに、OpenVLA-OFT[55]に代表される Action Head 型 VLA (Vision-Language-Action Model) のパラダイムを応用し、生体時系列データの生成に特化した出力ヘッドを Transformer に組み込むことで、複数モダリティにまたがる生体情報を統一的枠組みで処理することが可能となる。このような枠組みの下で、過去の臨床経過に基づいて将来の骨構造変化を予測し、治療介入の効果を計算機上で事前評価するシステムが実現すれば、本システムは精密医療を支えるデジタル・ツインの基盤技術となりうる。

以上のように、本研究で提示した ISBB は、現時点では概念実証の段階にあるものの、数理モデル、機械学習、臨床データの統合を実現するための基盤を提供している。今後、ヒト由来データによる検証と拡張を重ねることで、Virtual Physiological Human[56]が目指すような、骨代謝の数理的知見と、臨床における意思決定を橋渡しする実用的システムへと発展する可能性を有している。

第 5 章 結言

高齢社会において、骨粗鬆症は健康寿命を延伸する上での大きな阻害要因となっている。従来の診断手法では、非侵襲性と取得情報量の間にトレードオフが存在し、侵襲的な骨生検に代わる手法が求められていた。この課題を克服するため、本研究は、非侵襲的に取得可能な臨床指標から、個別の患者における詳細な骨内部状態を推定し、可視化する計算システム、**In-Silico Bone Biopsy (ISBB)** の実現を目的とした。

ISBB は、統計的学習に基づく機械学習モデルと、物理法則に基づいた数理シミュレータを疎に結合させた、**modular 型 Gray-box** アプローチに基づいて構築されている。このアプローチは、データへの高い適応能力を持つが解釈性に課題のある **Black-box** アプローチと、解釈性に優れるが個別適応が困難な **White-box** アプローチの長所を統合したものであり、生理学的整合性と個別データへの適応能力を両立する新たな枠組みである。

機械学習モデルの構築においては、大規模臨床データセットである **NHANES** を用いてアルゴリズムの比較検証を実施した。その結果、血清データやデモグラフィック情報等から骨密度を予測するタスクにおいて、予測値の期待値と分散を同時に出力する **Heteroscedastic** 回帰が、決定係数 $R^2 = 0.611 \pm 0.005$ という最も高い汎化性能を示し、生体データに内在する不確実性の定量化を可能とした。

本研究の中核をなす数理シミュレータとしては、自動微分フレームワーク **JAX** を基盤とした微分可能骨代謝シミュレータを開発した。本シミュレータは、有限要素法による力学解析、力学から生化学へのシグナル変換、反応拡散系によるシグナル分子濃度計算、移流反応拡散系による細胞動態、**Phase Field** 法による形状変化を、連続値の場として統合したマルチフィジックスモデルである。

順解析による検証では、単一骨梁スケールから組織スケールに至るまで、荷重条件に応じた力学適応を安定的に再現できることを確認した。例えば組織スケールでは、荷重方向に応じて **MIL** ファブリック楕円体の主軸方向が変化し、構造異方性比も増大した。さらに、力学負荷の低下や生化学的因子の変調に伴う、多様な骨疾患の進行過程を単一の数理モデルで再現可能であることを示した。

逆解析の枠組みにおいては、シミュレータが提供する勾配情報を活用するアルゴリズムにより、高次元パラメータ空間における効率的な探索を実現した。双子実験による検証では、勾配ベースの最適化アルゴリズムである **AdamW** が、従来の勾配フリー手法である **Nelder-Mead** 法と比較して、4 種の細胞活性パラメータの推定において高い精度と安定性を有することを実証した。

さらに、実際の臨床データである **NHANES** を用いたケーススタディを実施した。その結果、本システムが、臨床データに基づき推定した静的な骨量を表す **BV/TV** と、動的な骨代謝状態を表す骨形成量および骨吸収量を境界条件とする逆解析により、詳細な骨内部状態を推定可能であることを示した。さらに、その推定状態に基づく順解析を通じて、患者の代謝バランスに応じた骨量の経時変化と、その背景にある骨リモデリング動態を観察可能であることを実証した。

以上のように本研究は、機械学習と微分可能シミュレータの融合により、これまで侵襲性の高い手法を通じてしか得られなかったような詳細な骨内部情報を、非侵襲な臨床データに基づき推定し、さらにその動的振る舞いを可視化する **In-Silico Bone Biopsy** システムを実現するための基盤を確立した。本システムが提供する患者個別性と解釈可能性は、骨粗鬆症の病態理解を深化させ、個々の患者の代謝状態に応じた精密な治療方針の策定に寄与するものである。今後の展望としては、ヒト由来の骨微細構造データを用いた検証、不確実性を定量化するベイズ的推論への拡張、データ駆動型多臓器連関モデルとの統合などを通じて、臨床現場における実用的な意思決定支援システムとしての発展が期待される。

参考文献

- [1] T. J. Martin and N. A. Sims, ‘Osteoclast-derived activity in the coupling of bone formation to resorption’, *Trends Mol. Med.*, vol. 11, no. 2, pp. 76–81, Feb. 2005, doi: 10.1016/j.molmed.2004.12.004.
- [2] R. Baron and M. Kneissel, ‘WNT signaling in bone homeostasis and disease: from human mutations to treatments’, *Nat. Med.*, vol. 19, no. 2, pp. 179–192, Feb. 2013, doi: 10.1038/nm.3074.
- [3] 厚生労働省, ‘2022（令和4）年 国民生活基礎調査の概況’. 厚生労働省, 東京, Jul. 04, 2023. [Online]. Available: <https://www.mhlw.go.jp/toukei/saikin/hw/k-tyosa/k-tyosa22/dl/14.pdf>
- [4] Nih Consensus Development Panel On Osteoporosis Prevention, Diagnosis, And Therapy, ‘Osteoporosis Prevention, Diagnosis, and Therapy’, *JAMA J. Am. Med. Assoc.*, vol. 285, no. 6, pp. 785–795, Feb. 2001, doi: 10.1001/jama.285.6.785.
- [5] E. Seeman and P. D. Delmas, ‘Bone Quality — The Material and Structural Basis of Bone Strength and Fragility’, *N. Engl. J. Med.*, vol. 354, no. 21, pp. 2250–2261, May 2006, doi: 10.1056/NEJMr053077.
- [6] R. P. Crawford, C. E. Cann, and T. M. Keaveny, ‘Finite element models predict in vitro vertebral body compressive strength better than quantitative computed tomography’, *Bone*, vol. 33, no. 4, pp. 744–750, Oct. 2003, doi: 10.1016/S8756-3282(03)00210-2.
- [7] H. K. Genant *et al.*, ‘Noninvasive assessment of bone mineral and structure: State of the art’, *J. Bone Miner. Res.*, vol. 11, no. 6, pp. 707–730, Jun. 1996, doi: 10.1002/jbmr.5650110602.
- [8] for the IOF-IFCC Bone Marker Standards Working Group *et al.*, ‘Markers of bone turnover for the prediction of fracture risk and monitoring of osteoporosis treatment: a need for international reference standards’, *Osteoporos. Int.*, vol. 22, no. 2, pp. 391–420, Feb. 2011, doi: 10.1007/s00198-010-1501-1.
- [9] S. Treurniet, E. M. W. Eekhoff, F. N. Schmidt, D. Micha, B. Busse, and N. Bravenboer, ‘A Clinical Perspective on Advanced Developments in Bone Biopsy Assessment in Rare Bone Disorders’, *Front. Endocrinol.*, vol. 11, p. 399, Jun. 2020, doi: 10.3389/fendo.2020.00399.
- [10] Y. Kameo, Y. Miya, M. Hayashi, T. Nakashima, and T. Adachi, ‘In silico experiments of bone remodeling explore metabolic diseases and their drug treatment’, *Sci. Adv.*, vol. 6, no. 10, p. eaax0938, Mar. 2020, doi: 10.1126/sciadv.aax0938.
- [11] A. J. London, ‘Artificial Intelligence and Black-Box Medical Decisions: *Accuracy versus Explainability*’, *Hastings Cent. Rep.*, vol. 49, no. 1, pp. 15–21, Jan. 2019, doi: 10.1002/hast.973.
- [12] M. Raissi, P. Perdikaris, and G. E. Karniadakis, ‘Physics-informed neural networks:

- A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations', *J. Comput. Phys.*, vol. 378, pp. 686–707, Feb. 2019, doi: 10.1016/j.jcp.2018.10.045.
- [13] J. J. Kendall *et al.*, 'An in silico micro-multiphysics agent-based approach for simulating bone regeneration in a mouse femur defect model', *Front. Bioeng. Biotechnol.*, vol. 11, p. 1289127, Dec. 2023, doi: 10.3389/fbioe.2023.1289127.
 - [14] B. Shahriari, K. Swersky, Z. Wang, R. P. Adams, and N. De Freitas, 'Taking the Human Out of the Loop: A Review of Bayesian Optimization', *Proc. IEEE*, vol. 104, no. 1, pp. 148–175, Jan. 2016, doi: 10.1109/JPROC.2015.2494218.
 - [15] J. A. Nelder and R. Mead, 'A Simplex Method for Function Minimization', *Comput. J.*, vol. 7, no. 4, pp. 308–313, Jan. 1965, doi: 10.1093/comjnl/7.4.308.
 - [16] M. Walle, F. C. Marques, N. Ohs, M. Blauth, R. Müller, and C. J. Collins, 'Bone Mechanoregulation Allows Subject-Specific Load Estimation Based on Time-Lapsed Micro-CT and HR-pQCT in Vivo', *Front. Bioeng. Biotechnol.*, vol. 9, p. 677985, Jun. 2021, doi: 10.3389/fbioe.2021.677985.
 - [17] H. Aftabi *et al.*, 'OsteoOpt: A Bayesian Optimization Framework for Enhancing Bone Union Likelihood in Mandibular Reconstruction Surgery'.
 - [18] L. M. Rios and N. V. Sahinidis, 'Derivative-free optimization: a review of algorithms and comparison of software implementations', *J. Glob. Optim.*, vol. 56, no. 3, pp. 1247–1293, Jul. 2013, doi: 10.1007/s10898-012-9951-y.
 - [19] J. Degraeve, M. Hermans, J. Dambre, and F. Wyffels, 'A Differentiable Physics Engine for Deep Learning in Robotics', Nov. 24, 2018, *arXiv*: arXiv:1611.01652. doi: 10.48550/arXiv.1611.01652.
 - [20] B. Suh *et al.*, 'Interpretable Deep-Learning Approaches for Osteoporosis Risk Screening and Individualized Feature Analysis Using Large Population-Based Data: Model Development and Performance Evaluation', *J. Med. Internet Res.*, vol. 25, p. e40179, Jan. 2023, doi: 10.2196/40179.
 - [21] J. H. Friedman, 'Greedy function approximation: A gradient boosting machine.', *Ann. Stat.*, vol. 29, no. 5, Oct. 2001, doi: 10.1214/aos/1013203451.
 - [22] A. Vaswani *et al.*, 'Attention Is All You Need', Aug. 02, 2023, *arXiv*: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.
 - [23] J. Ho and T. Salimans, 'Classifier-Free Diffusion Guidance', Jul. 26, 2022, *arXiv*: arXiv:2207.12598. doi: 10.48550/arXiv.2207.12598.
 - [24] D. A. Nix and A. S. Weigend, 'Estimating the mean and variance of the target probability distribution', in *Proceedings of 1994 IEEE International Conference on Neural Networks (ICNN'94)*, Orlando, FL, USA: IEEE, 1994, pp. 55–60 vol.1. doi: 10.1109/ICNN.1994.374138.
 - [25] L. Georgiou, T. L. Kivell, D. H. Pahr, L. T. Buck, and M. M. Skinner, 'Trabecular architecture of the great ape and human femoral head', *J. Anat.*, vol. 234, no. 5, pp.

- 679–693, May 2019, doi: 10.1111/joa.12957.
- [26] E. Perilli *et al.*, ‘Failure strength of human vertebrae: Prediction using bone mineral density measured by DXA and bone volume by micro-CT’, *Bone*, vol. 50, no. 6, pp. 1416–1425, Jun. 2012, doi: 10.1016/j.bone.2012.03.002.
 - [27] R. Swaminathan, ‘Biochemical markers of bone turnover’.
 - [28] B. van Rietbergen, H. Weinans, R. Huiskes, and A. Odgaard, ‘A NEW METHOD TO DETERMINE TRABECULAR BONE ELASTIC PROPERTIES AND LOADING USING MICROMECHANICAL FINITE-ELEMENT MODELS’.
 - [29] M. P. Bendsøe and N. Kikuchi, ‘Generating optimal topologies in structural design using a homogenization method’, *Comput. Methods Appl. Mech. Eng.*, vol. 71, no. 2, pp. 197–224, Nov. 1988, doi: 10.1016/0045-7825(88)90086-2.
 - [30] T. Adachi, K. Tsubota, Y. Tomita, and S. J. Hollister, ‘Trabecular Surface Remodeling Simulation for Cancellous Bone Using Microstructural Voxel Finite Element Models’, *J. Biomech. Eng.*, vol. 123, no. 5, pp. 403–409, Oct. 2001, doi: 10.1115/1.1392315.
 - [31] A. G. Robling *et al.*, ‘Mechanical Stimulation of Bone in Vivo Reduces Osteocyte Expression of Sost/Sclerostin’, *J. Biol. Chem.*, vol. 283, no. 9, pp. 5866–5875, Feb. 2008, doi: 10.1074/jbc.M705092200.
 - [32] M. Hayashi, T. Nakashima, M. Taniguchi, T. Kodama, A. Kumanogoh, and H. Takayanagi, ‘Osteoprotection by semaphorin 3A’, *Nature*, vol. 485, no. 7396, pp. 69–74, May 2012, doi: 10.1038/nature11000.
 - [33] K. Fuller *et al.*, ‘Cathepsin K inhibitors prevent matrix-derived growth factor degradation by human osteoclasts’, *Bone*, vol. 42, no. 1, pp. 200–211, Jan. 2008, doi: 10.1016/j.bone.2007.09.044.
 - [34] S. Aland, F. Stenger, R. Müller, A. Deutsch, and A. Voigt, ‘A Phase Field Approach to Trabecular Bone Remodeling’, *Front. Appl. Math. Stat.*, vol. 6, p. 12, May 2020, doi: 10.3389/fams.2020.00012.
 - [35] S. M. Allen and J. W. Cahn, ‘A microscopic theory for antiphase boundary motion and its application to antiphase domain coarsening’, *Acta Metall.*, vol. 27, no. 6, pp. 1085–1095, Jun. 1979, doi: 10.1016/0001-6160(79)90196-2.
 - [36] R. Frostig, M. J. Johnson, and C. Leary, ‘Compiling machine learning programs via high-level tracing’.
 - [37] D. G. Anderson, ‘Iterative Procedures for Nonlinear Integral Equations’, *J. ACM*, vol. 12, no. 4, pp. 547–560, Oct. 1965, doi: 10.1145/321296.321305.
 - [38] D. P. Kingma and J. Ba, ‘Adam: A Method for Stochastic Optimization’, Jan. 30, 2017, *arXiv*: arXiv:1412.6980. doi: 10.48550/arXiv.1412.6980.
 - [39] I. Loshchilov and F. Hutter, ‘Decoupled Weight Decay Regularization’, Jan. 04, 2019, *arXiv*: arXiv:1711.05101. doi: 10.48550/arXiv.1711.05101.
 - [40] D. C. Liu and J. Nocedal, ‘On the limited memory BFGS method for large scale

- optimization’, *Math. Program.*, vol. 45, no. 1–3, pp. 503–528, Aug. 1989, doi: 10.1007/BF01589116.
- [41] W. J. Whitehouse, ‘The quantitative morphology of anisotropic trabecular bone’, *J. Microsc.*, vol. 101, no. 2, pp. 153–168, Jul. 1974, doi: 10.1111/j.1365-2818.1974.tb03878.x.
 - [42] C. C. Wu *et al.*, ‘Diagnosis and Management of Osteopetrosis: Consensus Guidelines From the Osteopetrosis Working Group’, *J. Clin. Endocrinol. Metab.*, vol. 102, no. 9, pp. 3111–3123, Sep. 2017, doi: 10.1210/je.2017-01127.
 - [43] A. D. LeBlanc, E. R. Spector, H. J. Evans, and J. D. Sibonga, ‘Skeletal responses to space flight and the bed rest analog: A review’.
 - [44] J. A. Kanis and J. A. Kanis, ‘Assessment of fracture risk and its application to screening for postmenopausal osteoporosis: Synopsis of a WHO report’, *Osteoporos. Int.*, vol. 4, no. 6, pp. 368–381, Nov. 1994, doi: 10.1007/BF01622200.
 - [45] T. Bonnaire, R. Urfin, G. Biroli, and M. Mézard, ‘Why Diffusion Models Don’t Memorize: The Role of Implicit Dynamical Regularization in Training’.
 - [46] X. Huang, A. Khetan, M. Cvitkovic, and Z. Karnin, ‘TabTransformer: Tabular Data Modeling Using Contextual Embeddings’, Dec. 11, 2020, *arXiv*: arXiv:2012.06678. doi: 10.48550/arXiv.2012.06678.
 - [47] A. G. Baydin, B. A. Pearlmutter, A. A. Radul, and J. M. Siskind, ‘Automatic differentiation in machine learning: a survey’, Feb. 05, 2018, *arXiv*: arXiv:1502.05767. doi: 10.48550/arXiv.1502.05767.
 - [48] J. Aerssens, S. Boonen, G. Lowet, and J. Dequeker, ‘Interspecies Differences in Bone Composition, Density, and Quality: Potential Implications for in Vivo Bone Research’, vol. 139, no. 2.
 - [49] L. Pothuau, N. Barthe, M.-A. Krieg, N. Mehsen, P. Carceller, and D. Hans, ‘Evaluation of the Potential Use of Trabecular Bone Score to Complement Bone Mineral Density in the Diagnosis of Osteoporosis: A Preliminary Spine BMD–Matched, Case-Control Study’, *J. Clin. Densitom.*, vol. 12, no. 2, pp. 170–176, Apr. 2009, doi: 10.1016/j.jocd.2008.11.006.
 - [50] M. A. Bouhlel and J. R. R. A. Martins, ‘Gradient-enhanced kriging for high-dimensional problems’, *Eng. Comput.*, vol. 35, no. 1, pp. 157–173, Jan. 2019, doi: 10.1007/s00366-018-0590-x.
 - [51] C. de Vente, M. M. Islam, P. Valmaggia, C. Hoyng, A. Tufail, and C. I. Sánchez, ‘Conditioning 3D Diffusion Models with 2D Images: Towards Standardized OCT Volumes through En Face-Informed Super-Resolution’, Oct. 13, 2024, *arXiv*: arXiv:2410.09862. doi: 10.48550/arXiv.2410.09862.
 - [52] J. Ho, A. Jain, and P. Abbeel, ‘Denoising Diffusion Probabilistic Models’, Dec. 16, 2020, *arXiv*: arXiv:2006.11239. doi: 10.48550/arXiv.2006.11239.
 - [53] M. C. Kennedy and A. O’Hagan, ‘Bayesian Calibration of Computer Models’, *J. R.*

- Stat. Soc. Ser. B Stat. Methodol.*, vol. 63, no. 3, pp. 425–464, Sep. 2001, doi: 10.1111/1467-9868.00294.
- [54] R. Chang *et al.*, ‘Organ-Agents: Virtual Human Physiology Simulator via LLMs’, Aug. 20, 2025, *arXiv*: arXiv:2508.14357. doi: 10.48550/arXiv.2508.14357.
- [55] M. J. Kim, C. Finn, and P. Liang, ‘Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success’, Apr. 28, 2025, *arXiv*: arXiv:2502.19645. doi: 10.48550/arXiv.2502.19645.
- [56] M. Viceconti and P. Hunter, ‘The Virtual Physiological Human: Ten Years After’, *Annu. Rev. Biomed. Eng.*, vol. 18, no. 1, pp. 103–123, Jul. 2016, doi: 10.1146/annurev-bioeng-110915-114742.

謝辞

本研究の遂行にあたり，京都大学医生物学研究所の安達泰治教授より，貴重な御指導を賜りました．ここに謹んで感謝の意を表します．本論文の執筆をはじめ，研究全般に関して，京都大学医生物学研究所の金英寛助教より，直接の御指導を賜りました．終始，懇切丁寧に御指導頂きましたことを，厚く御礼申し上げます．また，京都大学医生物学研究所の牧功一郎准教授，竹田宏典助教より，日頃の研究活動，及び学生生活において，有益な御助言と御指導を賜りました．心より感謝申し上げます．さらに，日頃の研究活動，及び学生生活において，有益なご助言を賜りました京都大学医生物学研究所の須長純子氏，平良美智代氏に深く感謝致します．

京都大学大学院工学研究科修士課程 1 回生の赤地悠清氏には，研究の遂行と本論文の執筆に関して，多大なご支援をして頂きました．心より感謝申し上げます．京都大学大学院工学研究科マイクロエンジニアリング専攻バイオメカニクス分野の諸氏からは，研究活動のみならず，学生生活の公私にわたって大変な御助力を賜りました．互いに励ましあい，切磋琢磨した同輩をはじめとするバイオメカニクス分野の諸氏に心から感謝の意を表します．

最後に，ここまで精神的，経済的に支えてくれた家族に心から感謝致します．

2026 年 2 月 平塚謙良

付録

S.1

組織スケールの実験におけるシミュレータの各パラメータ値を Table S1 に示す.

Table S1 組織スケールの実験におけるシミュレータのパラメータ値

記号	説明	値 (単位)	単位
ΔT	時間ステップ幅	1.0	Day
Δx	ボクセル幅	0.024	mm
$aa_{\max}$	Anderson Acceleration の最大反復回数	1.0×10^2	—
aa_{tol}	Anderson Acceleration の許容誤差	1.0×10^{-4}	—
$cg_{\max}$	CG 法の最大反復回数	1.0×10^6	—
cg_{tol}	CG 法の許容誤差	1.0×10^{-6}	—
pf_{steps}	Phase Field 法のサブステップ数	10	—
E_{marrow}	骨髄のヤング率	1.0	MPa
ν_{marrow}	骨髄のポアソン比	0.3	—
E_{bone}	骨のヤング率	2.0×10^4	MPa
ν_{bone}	骨のポアソン比	0.3	—
E_{fixture}	支持部材のヤング率	2.0×10^3	MPa
ν_{fixture}	支持部材のポアソン比	0.3	—
ll	骨細胞による力学刺激の感知範囲	0.1	mm
ρ_{ocy}	骨細胞密度	2.5×10^4	1/mm ³
$\sigma_{\max}$	力学刺激の上限閾値	20.0	MPa
$\sigma_{\min}$	力学刺激の下限閾値	5.0	MPa
k_{stress}	力学刺激感度係数	2.0	1/MPa
K_{SCL}	力学刺激による Sclerostin 産生抑制の閾値	0.98	—
n_{SCL}	Sclerostin の Hill 係数	9.0	—
β_{SCL}	Sclerostin の最大産生速度	3.375×10^{-12}	pM/s
c_{SCL}	Sclerostin の最低産生速度	0.0	pM/s
D_{SCL}	Sclerostin の拡散係数	5.58×10^{-6}	mm ² /s
$k_{\text{deg}}^{\text{SCL}}$	Sclerostin の分解速度定数	5.0×10^{-3}	1/s
K_{RANKL}	Sclerostin 濃度による RANKL 産生促進の閾値	15.0	pM
n_{RANKL}	RANKL の Hill 係数	3.0	—
β_{RANKL}	RANKL の最大産生速度	3.375×10^{-12}	pM/s
c_{RANKL}	RANKL の最低産生速度	0.0	pM/s
D_{RANKL}	RANKL の拡散係数	5.32×10^{-6}	mm ² /s
$k_{\text{deg}}^{\text{RANKL}}$	RANKL の分解速度定数	5.0×10^{-3}	1/s
$k_{\text{on}}^{\text{RO}}$	RANKL-OPG 結合の結合速度	0.1	1/pMs
β_{OPG}	OPG の最大産生速度	3.375×10^{-12}	pM/s

c_{OPG}	OPG の最低産生速度	0.0	pM/s
D_{OPG}	OPG の拡散係数	4.49×10^{-6}	mm^2/s
$k_{\text{deg}}^{\text{OPG}}$	OPG の分解速度定数	5.0×10^{-3}	$1/s$
P_{Sema3A}	Sema3A の産生速度	3.375×10^{-12}	pM/s
D_{Sema3A}	Sema3A の拡散係数	3.62×10^{-6}	mm^2/s
$k_{\text{deg}}^{\text{Sema3A}}$	Sema3A の分解速度定数	5.0×10^{-3}	$1/s$
K_{Nrp1}	RANKL 濃度による Nrp1 産生抑制の閾値	1.0	pM
n_{Nrp1}	Nrp1 の Hill 係数	9.0	—
β_{Nrp1}	Nrp1 の最大産生速度	5.0×10^{-2}	pM/s
$k_{\text{deg}}^{\text{Nrp1}}$	Nrp1 の分解速度	5.0×10^{-3}	pM/s
C_{PlxnA1}	PlxnA1 の濃度	10.0	pM
$k_{\text{on}}^{\text{NP}}$	Nrp1-PlxnA1 結合の結合速度	0.1	$1/pMs$
$k_{\text{on}}^{\text{SNP}}$	Sema3A-Nrp1-PlxnA1 結合の結合速度	1.0	$1/pMs$
P_{MDGF}	MDGF の最大産生速度	3.375×10^{-12}	pM/s
c_{MDGF}	MDGF の最低産生速度	0.0	pM/s
D_{MDGF}	MDGF の拡散係数	4.56×10^{-6}	mm^2/s
$k_{\text{deg}}^{\text{MDGF}}$	MDGF の分解速度定数	0.1	$1/s$
n_{cell}	細胞動態モデルに共通の Hill 係数	6.0	—
$K_{\text{Ocy,Ocl}}^{\text{apop}}$	力学刺激による Osteoclast アポトーシス誘導の閾値	0.98	—
$K_{\text{MDGF,Ocl}}^{\text{apop}}$	MDGF 濃度による Osteoclast アポトーシス誘導の閾値	2.5	pM
$\alpha_{\text{MDGF,Ocl}}^{\text{apop}}$	Osteoclast アポトーシスに対する MDGF 効果のスケーリング係数	1.0	—
$K_{\text{SCL,Obl}}^{\text{apop}}$	Sclerostin 濃度による Osteoblast アポトーシス誘導の閾値	9.0	pM
$K_{\text{MDGF,Obl}}^{\text{apop}}$	MDGF 濃度による Osteoblast アポトーシス抑制の閾値	2.5	pM
$\alpha_{\text{MDGF,Obl}}^{\text{apop}}$	Osteoblast アポトーシスに対する MDGF 効果のスケーリング係数	1.0	—
$K_{\text{Ocy,Obl}}^{\text{apop}}$	力学刺激による Osteoblast アポトーシス抑制の閾値	1.0	—
$K_{\text{SNP}}^{\text{diff}}$	SNP 濃度による Osteoclast 分化抑制と、Osteoblast 分化促進の閾値	3.0	pM
$K_{\text{RANKL,Ocl}}^{\text{diff}}$	RANKL 濃度による Osteoclast 分化促進の閾値	2.0×10^{-5}	pM
$K_{\text{mat,Ocl}}^{\text{diff}}$	骨年齢 t_{mat} による Osteoclast 分化促進の閾値	10.0	Day
$a_{\text{mat,Ocl}}^{\text{diff}}$	Osteoclast 分化に対する骨年齢 t_{mat} の効果のスケーリング係数	1.0	—
$K_{\text{MDGF,Obl}}^{\text{diff}}$	MDGF 濃度による Osteoblast 分化促進の閾値	3.0	pM

$\alpha_{\text{MDGF,Obl}}^{\text{diff}}$	Osteoblast 分化に対する MDGF 効果のスケール リング係数	0.3	—
$K_{\text{SCL,Obl}}^{\text{diff}}$	Sclerostin 濃度による Osteoblast 分化抑制の閾 値	8.0	pM
v_{tan}	Osteoclast の接線方向の移動速度係数	2.4×10^{-4}	mm/Day
v_{norm}	Osteoclast, Osteoblast の法線方向の移動速度 係数	0.048	mm/Day
w_{OPG}	Osteoclast 移動時の骨年齢 t_{mat} の勾配に対する OPG 勾配の重み	10.0	—
$\rho_{\text{Ocl}}^{\text{max}}$	Osteoclast の最大密度	7.23×10^4	$1/mm^3$
$\rho_{\text{Obl}}^{\text{max}}$	Osteoblast の最大密度	7.23×10^4	$1/mm^3$
$k_{\text{apop,Ocl}}$	Osteoclast のアポトーシス反応活性のスケーリ ング係数	5.0	—
$k_{\text{apop,Obl}}$	Osteoblast のアポトーシス反応活性のスケーリ ング係数	0.6	—
$k_{\text{diff,Ocl}}$	Osteoclast の分化反応活性のスケーリング係数	0.5	—
$k_{\text{diff,Obl}}$	Osteoblast の分化反応活性のスケーリング係数	6.0	—
k_{reset}	リバーサルフェーズの回復率	50.0	$1/Day$
k_{rejuv}	骨年齢 t_{mat} の回復率	50.0	$1/Day$
$t_{\text{mat}}^{\text{max}}$	骨の最大成熟期間	100.0	Day
T_{rev}	リバーサルフェーズの時定数	10.0	Day
$\dot{M}_{\text{r}}$	Osteoclast による界面後退速度	1.4×10^{-3}	mm/Day
$\dot{M}_{\text{f}}$	Osteoblast による界面成長速度	5.6×10^{-4}	mm/Day
ϵ	Phase Field 法の界面幅係数	0.024	mm
M	Phase Field 法のモビリティ係数	6.67×10^{-12}	mm^2/s

単一骨梁スケールの実験における各パラメータ値の Table S1 との差分を Table S2 に示す。

Table S2 単一骨梁スケールの実験におけるシミュレータのパラメータ値

記号	説明	値 (単位)	単位
E_{fixture}	支持部材のヤング率	2.0×10^5	MPa
σ_{min}	力学刺激の下限閾値	1.0	MPa
$k_{\text{deg}}^{\text{MDGF}}$	MDGF の分解速度定数	0.05	$1/s$
$K_{\text{MDGF,Ocl}}^{\text{apop}}$	MDGF 濃度による Osteoclast アポトーシス誘 導の閾値	2.0	pM
$K_{\text{SCL,Obl}}^{\text{apop}}$	Sclerostin 濃度による Osteoblast アポトーシス 誘導の閾値	10.0	pM
$K_{\text{MDGF,Obl}}^{\text{apop}}$	MDGF 濃度による Osteoblast アポトーシス抑	2.0	pM

	制の閾値		
$K_{\text{MDGF,Obl}}^{\text{diff}}$	MDGF 濃度による Osteoblast 分化促進の閾値	2.5	pM
$k_{\text{apop,Ocl}}$	Osteoclast のアポトーシス反応活性のスケーリング係数	1.0	—
$k_{\text{apop,Obl}}$	Osteoblast のアポトーシス反応活性のスケーリング係数	1.0	—
$k_{\text{diff,Ocl}}$	Osteoclast の分化反応活性のスケーリング係数	1.0	—
$k_{\text{diff,Obl}}$	Osteoblast の分化反応活性のスケーリング係数	1.0	—
$\dot{M}_r$	Osteoclast による界面後退速度	5.0×10^{-4}	mm/Day
$\dot{M}_f$	Osteoblast による界面成長速度	5.0×10^{-4}	mm/Day
ϵ	Phase Field 法の界面幅係数	0.072	mm
M	Phase Field 法のモビリティ係数	6.67×10^{-13}	mm^2/s

S.2




Fig. S1 閾値係数 k に対する R^2 決定係数の推移: Heteroscedastic 回帰モデルを用いて, 異なる seed で 3 回ずつ学習した. エラーバーはその標準偏差を示す.

Fig. S1 より $k \geq 2$ において R^2 決定係数に大きな変化が見られなかったため, ここでは $k = 6.5$ を採用した.

S.3

2.1.3 項の 2.3 式および 2.4 式の α, β は, 異なる骨量条件において骨量が定常となる骨形成量 V_{form} と骨吸収量 V_{res} の差を基準として決定した. 具体的には, 二つの BV/TV 条件 $(BV/TV_1, \Delta V_1)$, $(BV/TV_2, \Delta V_2)$ において, 定常状態を与える V_{form} と V_{res} の差 $\Delta V = V_{\text{form}} - V_{\text{res}}$ を数値的に求め, ΔV が BV/TV に対して一次近似的に変化すると仮定した. これに基づき, 任意の BV/TV における目標差 $\Delta V(BV/TV)$ を以下のように定義した.

$$\Delta V(BV/TV) = \frac{BV/TV - BV/TV_2}{BV/TV_1 - BV/TV_2} (\Delta V_1 - \Delta V_2) + \Delta V_2 \quad (\text{S.1})$$

この目標差 ΔV を 2.3 式および 2.4 式の α に対し以下のように対称に配分した.

$$\alpha_{\text{form}}^* = \alpha_{\text{base}} + \frac{1}{2} \Delta V \quad (\text{S.2})$$

$$\alpha_{\text{res}}^* = \alpha_{\text{base}} - \frac{1}{2} \Delta V \quad (\text{S.3})$$

なお, これらの操作は 4.2 節の課題で述べたように, Allen-Cahn 方程式の拡散項に伴う, 骨吸収量に対する非生理的なバイアスの影響を打ち消すことを目的としている. 各パラメータの値を Table S3 に示す.

Table S3 β および α を決定するために用いたパラメータ値

記号	値
BV/TV_1	0.29798
BV/TV_2	0.20993
ΔV_1	0.0000777
ΔV_2	0.0021976
α_{base}	0.003
β	0.0005

S.4

Fig. S2 より, V-Bone および D-Bone の両シミュレータにおいて, 処理時間はボクセル数に対して概ね線形に増加していることが確認できる. V-Bone (FP64) と D-Bone (FP64) の比較では, 後者が前者に対して約 5 倍の高速化を達成した. また, D-Bone における計算精度を FP64 から FP32 に変更した際, 処理時間は 1.5~4 倍程度短縮された.

特筆すべき点として, ボクセル数が増加するほど精度変更による処理時間短縮の効果が顕著であった. これは, 本シミュレータの実行速度が GPU の演算性能よりも, RAM・VRAM 間, あるいは VRAM・キャッシュ間におけるテンソルのデータ転送帯域に制約される, メモリ律速の状態にあることを示唆している. なお, 本検証に用いた計算機環境の詳細を Table S4 に示す.




Fig. S2 ボクセル数に対する V-Bone および D-Bone のシミュレーションの 1 ステップの実行時間：倍精度 (FP64) で設計されている V-Bone (赤) に対して、倍精度と単精度 (FP32) を切り替え可能な D-Bone を青、緑線で示す．それぞれの値はシミュレーションが十分に安定してから 10 ステップ分の処理にかかった時間の平均を取ったもの．左は通常の折れ線グラフであり、右は左図を両対数グラフとしたもの．

Table S4 各シミュレータの処理時間の検証に用いた計算機環境

	V-Bone	D-Bone
GPU 名	-	GeForce RTX 5090
VRAM 容量 [GB]	-	32
VRAM 帯域 [GB/s]	-	1792
CPU 名	Intel Xeon E5-2697A v4	Intel Core i7-12700
CPU コア/スレッド数	16 / 32	12 / 20
RAM 容量 [GB]	128	16
RAM 帯域 [MT/s]	2400	4800
OS 名	CentOS 6.7	Ubuntu 24.04.3